UNIVERSIDAD NACIONAL DE COLOMBIA
Sede-Medellin

Faculcultad de Ciencia
Regresión lineal
Estadistica

Comparación de modelos

Laura Flórez Ceballos
Juan David Garcia Zapata
Juan Diego Espinosa Hernandez
Jorge Andres Garcia
Katerin Gomez Castrillon

06/2023

Índice general

0.1. 2
0.2. Introducción 2
0.3. Lectura datos 2
0.3.1. Visualización de datos 3
0.4. Modelo a utilizar 3
0.5. Analisis descriptivo 4
0.5.1. Selecion de mejores y peores modelos 8
0.6. Conclusiones 9
0.7. Recomedaciónes 9
0.8. Refencias 9

0.1.

0.2. Introducción

1. Introducción a la técnica de árboles de regresión

Los árboles de regresión son una técnica ampliamente utilizada en análisis predictivos para problemas de regresión. A diferencia de los modelos lineales, los árboles de regresión son capaces de modelar relaciones no lineales y capturar patrones complejos en los datos. Estos modelos se basan en la construcción de un árbol de decisiones, donde cada nodo representa una característica y cada rama representa una regla de decisión. La interpretación de los árboles de regresión es relativamente sencilla, lo que facilita su aplicación en diferentes dominios.

2. Importancia de la comparativa entre modelos

En el ámbito de la modelización predictiva, existe una amplia gama de enfoques y algoritmos para construir modelos de regresión. Sin embargo, no todos los modelos son igualmente precisos y efectivos en la predicción de los valores de salida. Por lo tanto, es esencial llevar a cabo una comparativa entre diferentes modelos construidos de manera heterogénea. Esta comparativa permite identificar aquellos modelos que demuestran un desempeño superior en términos de precisión predictiva y, por lo tanto, son más confiables para realizar predicciones precisas en escenarios futuros.

3. Identificación de grupos de modelos

En este estudio, se construyeron 60 modelos de regresión heterogéneos utilizando los mismos conjuntos de datos. Cada modelo fue generado mediante la técnica de árboles de regresión, pero se aplicaron variaciones en la selección de variables de entrada y parámetros de construcción del árbol. Estas variaciones aseguraron la diversidad de los modelos construidos y permitieron explorar diferentes enfoques para la resolución del problema. Esta diversidad es crucial para identificar grupos de modelos con características y desempeños distintos.

0.3. Lectura datos

La lectura de los datos se realiza a partir del archivo en formato PDF proporcionado por el profesor Juan Carlos Correa Morales, docente de regresión lineal en la Universidad Nacional de Colombia. Del archivo extraemos dos bases de datos: la primera contiene los coeficientes de los modelos de regresión, mientras que la segunda incluye los datos utilizados para construir dichos modelos.

0.3.1. Visualización de datos

Figura 1: Base 1

Figura 2: Base 2

Si no le funciona los Qr puede acceder a traves de los siguientes link

De click a la base de datos que quiera visualizar

Base 1

Base 2

0.4. Modelo a utilizar

En concordancia con lo mencionado en la introducción y el marco teórico, utilizaremos árboles de regresión.

Justificación

Interpretación sencilla: Los árboles de regresión permiten una interpretación visual y fácil de entender de los resultados. Cada nodo y rama del árbol representa una condición o regla de decisión que se aplica a los datos, lo que facilita la comprensión de cómo se llega a las predicciones.

Manejo de variables predictoras de diferentes tipos: Los árboles de regresión pueden manejar variables predictoras de diferentes tipos, como variables categóricas y continuas. No es necesario realizar transformaciones adicionales en los datos antes de ajustar el modelo, lo que simplifica el proceso.

Capacidad para capturar relaciones no lineales: Los árboles de regresión pueden identificar y capturar relaciones no lineales entre las variables predictoras y la variable objetivo. Pueden dividir el espacio de características en regiones distintas y ajustar diferentes funciones lineales en cada región, lo que permite modelar patrones complejos en los datos.

Robustez ante valores atípicos y datos faltantes: Los árboles de regresión son menos sensibles a valores atípicos y datos faltantes en comparación con otros métodos de regresión. Dado que los árboles

se basan en divisiones recursivas del conjunto de datos, un valor atípico o un dato faltante solo afectará las predicciones en la parte del árbol donde se encuentre.

Versatilidad y aplicabilidad en diversos campos: Los árboles de regresión son ampliamente utilizados en diferentes campos, como la ciencia de datos, la economía, la medicina y la ingeniería. Su versatilidad y capacidad para manejar diferentes tipos de problemas hacen que sean una herramienta útil en diversas áreas de investigación y aplicación.

0.5. Analisis descriptivo

Para llevar a cabo este análisis, utilizaremos R como herramienta principal. En particular, nos apoyaremos en la función hclust(dist(x)), donde x representa nuestra base 1. Esta función se encargará de realizar todas las operaciones necesarias para agrupar modelos similares de manera efectiva.

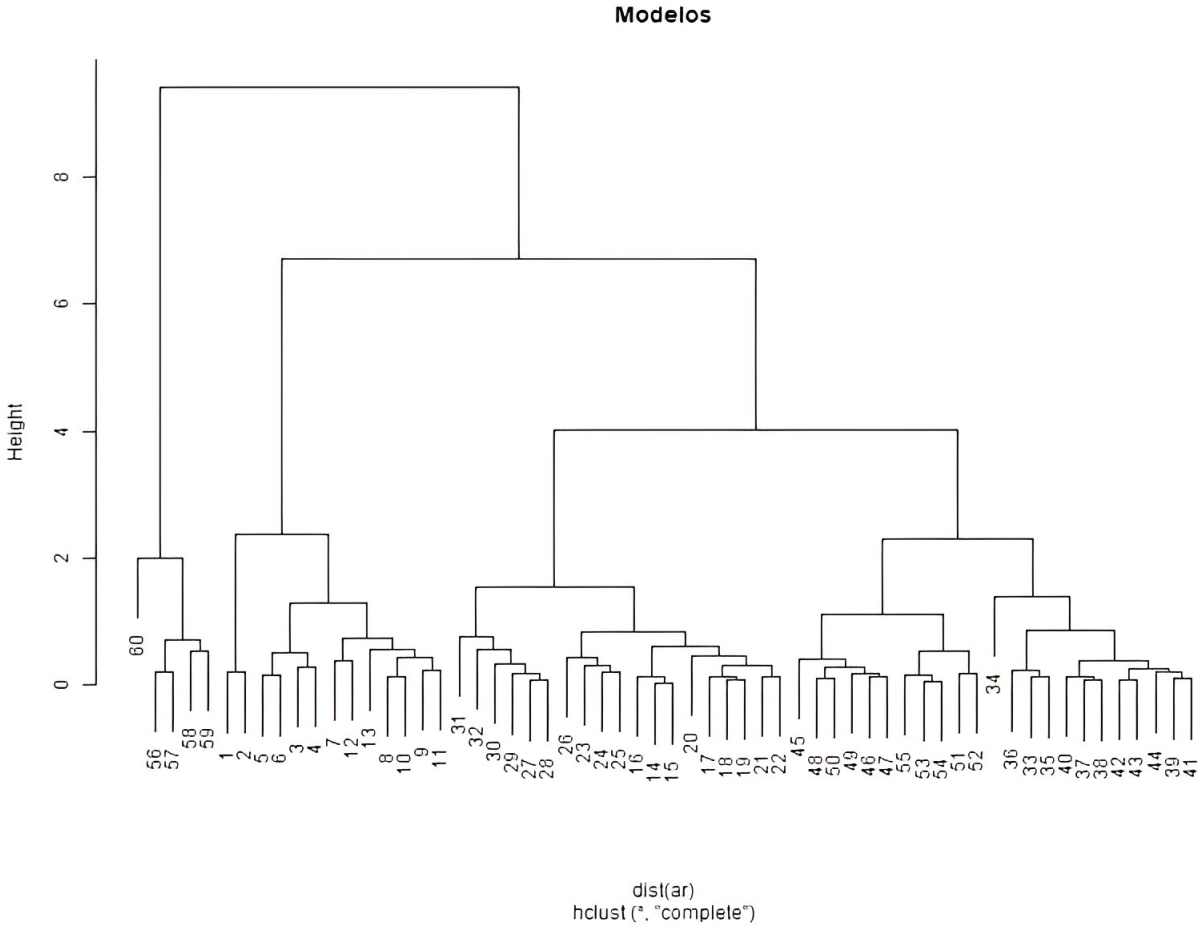

Figura 3: Arbol de regresión

Al analizar la función hclust(), que se encarga de calcular distancias y clasificar, observamos que asigna modelos similares a diferentes grupos. Sin embargo, esto no es suficiente, ya que no queda claro cuáles son los mejores. Por lo tanto, debemos establecer un criterio para seleccionar los mejores grupos de modelos. En este caso, nuestro criterio de decisión será el cálculo de la suma de cuadrados de los residuos (SCE), cuya fórmula es:

$$(y - \hat{y})'(y - \hat{y}) \tag{1}$$

Con este criterio, podemos determinar cuáles son los mejores modelos.

Para llevar a cabo este cálculo, necesitamos los estimados de los coeficientes 'y', los cuales se obtienen mediante los siguientes pasos:

1. Construcción de la matriz:
   - Matrix 1: contiene los coeficientes de los modelos, los cuales están en la base 1.
   - Matrix 2: corresponde a los datos utilizados para construir los modelos, los cuales están en la base 2.
2. Multiplicación de matrices
3. Estimación de $\hat{y}$

El primer paso se establece como una etapa preliminar en el análisis llevado a cabo mediante el lenguaje de programación R. Su finalidad es preparar de manera específica la multiplicación de las dos matrices involucradas en el proceso. Como resultado de esta multiplicación, se obtiene un vector que consta de 21 filas de $\hat{y}$ para cada modelo considerado. Esto implica que cada uno de estos modelos generará su propia estimación individual de $\hat{y}$.

Con esta preparación previa y habiendo calculado $\hat{y}$, podemos proceder a utilizar la ecuación (1). Es importante recordar que el vector de y, que representa la variable de respuesta en los modelos, nos es proporcionado por la base 2. A partir de ahí, aplicamos la fórmula correspondiente, lo cual nos arroja los siguientes resultados.

Modelo	**SCE**	**Modelo**	**SCE**	**Modelo**	**SCE**
1	207.16	21	196.46	41	242.79
2	208.11	22	187.59	42	210.77
3	224.01	23	13160.46	43	210.78
4	196.11	24	179.65	44	240.66
5	226.71	25	181.29	45	516.31
6	227.65	26	197.57	46	213.95
7	188.71	27	196.73	47	226.94
8	230.93	28	193.89	48	631.07
9	8635.49	29	202.97	49	205.83
10	219.87	30	8085.32	50	285.29
11	8217.95	31	178.83	51	245.01
12	185.14	32	226.69	52	240.67
13	222.79	33	202.97	53	246.83
14	186.60	34	10879.00	54	243.91
15	187.05	35	203.70	55	240.58
16	184.38	36	212.14	56	251.53
17	194.23	37	207.37	57	251.96
18	199.19	38	216.97	58	2080.10
19	196.85	39	229.22	59	260.43
20	234.85	40	207.62	60	369.47

Cuadro 1: Resultados

Con estos resultados, podemos establecer un criterio para clasificar los mejores modelos. Sin embargo, antes de hacerlo, necesitamos crear grupos utilizando diferentes puntos de corte. Para lograr esto, utilizaremos la función cutree(ae, k=i) en R, donde 'i' representa el número de cortes deseado y 'ae' es nuestro árbol de regresión. Esta función nos permitirá formar los grupos deseados y determinar cómo se clasifican los modelos en cada uno de ellos.

para esto tendremos de corte 8,7,6,5,4,3,2, uno no se considera ya que seria considerar a todos como los mejores modelos entonces tenemos:

afterpage

CORTES	grupo 1	grupo 2	grupo 3	grupo 4	grupo 5	grupo 6	grupo 7	grupo 8
8	1,2	3,4,5,6, 7,8,9,10, 11,12,13	14,15,16, 17,18, 19, 20,21,22, 23,24,25, 26	27,28,29, 30,31,32	33,34,35, 36,37,38, 39,40,41, 42,43,44	45,46,47, 48,49,50, 51,52,53, 54,55	56, 57, 58, 59	60
7	1,2	3,4,5,6, 7,8,9,10, 11,12,13	14,15,16, 17,18,19, 20,21,22, 23,24,25, 26,27,28, 29,30,21, 32	33,34,35, 36,37,38, 39,40,41,42, 43,44	45,46,47, 48,49,50, 51,54,55	56, 57, 58, 59	60	0
6	1,2	3,4,5,6,7, 8,9,10, 11,12,13	14,15,16, 17,18,19, 20,21,22, 23,24,25, 26,27,28, 29,30,31, 32	33,34,35, 36,37,38, 39,40,41, 42,43,44	45,46,47, 48,49,50, 51,52,53, 54,55	56, 57, 58, 59, 60	0	0
5	1,2	3,4,5,6,7, 8,9,10,11, 12,13	14,15,16, 17,18,19, 20,21,22, 23,24,25, 26,27,28, 29,30,31, 32	33,34,35, 36,37,38, 39,40,41, 42,43,44, 45,46,47, 48,49,50, 51,52,53, 54,55	56,57,58, 59,60	0	0	0
4	1,2,3,4, 5,6,7, 8,9,10,11, 12	13,14,15, 16,17,18, 19,20,21, 22,23,24, 25,26,27, 28,29,30, 31,32	33,34,35, 36,37,38, 39,40,41, 42,43,44, 45,46,47, 48,49,50, 51,52,53, 54,55,56	57,58,59, 60	0	0	0	0
3	1,2,3,4, 5,6,7,8, 9,10,11, 12	13,14,15,16, 17,18,19, 20,21,22,23, 24,25,26, 27,28,29,30, 31,32,33, 34,35,36,37, 38,39,40, 41,42,43,44, 45,46,47, 48,49,50,51, 52,53,54,55, 56	56,58,59, 60	0	0	0	0	0
2	1,2,3,4, 5,6,7,8, 9,10,11,12, 13,14,15, 16,17,18, 19,20,21, 22,23,24, 25,26,27, 28,29,30,31, 32,33,34,	56, 58, 59, 60	7 0	0	0	0	0	0

La tabla proporcionada contiene información detallada sobre cada corte realizado, incluyendo el número de grupos generados por cada corte. Además, se incluye información sobre a qué grupo pertenece cada modelo después de los cortes, los 0 es porque a ese corte no habian modelos asignado a ese grupo.

Esta tabla es invaluable para comprender cómo se forman los grupos y cómo los modelos son asignados a cada uno de ellos. Al examinar cuidadosamente esta información, podemos identificar patrones y tendencias que nos ayudarán a entender mejor la distribución y la pertenencia de los modelos en los diferentes grupos.

Al utilizar esta tabla como referencia, podemos realizar un análisis más profundo de los resultados obtenidos en los cortes. Esto nos permitirá extraer conclusiones más sólidas sobre la relación entre las características de los modelos y su asignación a grupos específicos. Además, también podremos identificar posibles influencias o factores que pueden haber influido en la formación de ciertos grupos. En cada grupo, calcularemos el promedio de la suma de los cuadrados de los residuos (SCE). Esto nos permitirá obtener conclusiones sobre cuáles son los mejores modelos. Sin embargo, también añadiremos una sección adicional para identificar cuáles son los peores grupos.

0.5.1. Selecion de mejores y peores modelos

En cada uno de nuestros grupos, realizamos el cálculo promedio de cada corte. A continuación, resumimos estos resultados en la siguiente tabla.

booktabs

Aquí se presenta la tabla con los resultados promedio de cada corte en cada grupo:

CORTES	grupo 1	grupo 2	grupo 3	grupo 4	grupo 5	grupo 6	grupo 7	grupo 8
8	207.6364	1706.851	1191.243	1514.072	1105.332	299.671	711.0053	369.4698
7	207.6364	1706.851	1293.189	1105.332	299.671	711.0053	369.4698	
6	207.6364	1706.851	1293.189	1105.332	299.671	642.6982		
5	207.6364	1706.851	1293.189	720.0159	642.6982			
4	1476.203	1293.189	720.0159	642.6982				
3	1476.203	979.3086	642.6982					
2	1096.756	642.6982						

Una vez completado este paso, procedemos a identificar el valor máximo y mínimo de la SCE para cada corte.

corte(grupo)	valor1	Valor2	Modelos1	Modelos2
2	642.6982	1096.7563	56:60	1:55
3	642.6982	1476.2027	56:60	1:13
4	642.6982	1476.2027	56:60	1:13
5	207.6364	1706.8511	1:2	3:13
6	207.6364	1706.8511	1:2	3:13
7	207.6364	1706.8511	1:2	3:13
8	207.6364	1706.8511	1:2	3:13

En la tabla anterior, el valor1 corresponde al SCE menor en ese corte, mientras que el valor2 corresponde al SCE mayor en ese corte. Además, la variable Modelos1 indica los mejores modelos, a diferencia de la variable Modelos2, que indica los peores modelos.

0.6. Conclusiones

Finalmente, podemos responder al objetivo planteado al inicio de nuestro estudio. Según los resultados obtenidos en diferentes cortes, se observa que existen variaciones en los resultados. En los cortes 2, 3 y 4, los mejores modelos se encuentran en el rango del 56 al 60, mientras que los peores modelos se sitúan entre el 1 y el 13. Sin embargo, en los cortes 5, 6, 7 y 8, los mejores modelos son el 1 y el 2, mientras que los peores se encuentran en el rango del 3 al 13.

Estos cambios pueden explicarse debido a que, en diferentes cortes, se agrupan distintos conjuntos de modelos. Es decir, cuando se reducen los grupos al promediar los SCE, las diferencias entre los modelos no se reflejan significativamente. Observamos que los modelos del 56 al 60, presentes en el árbol de regresión, siempre quedan en un solo grupo, ya que son notablemente distintos de los demás modelos. Por otro lado, los otros modelos, aunque se agrupan de manera diferente en cortes diferentes, generan grupos con una cantidad constante de modelos al promediar en los cortes 2, 3 y 4. Esto hace que los mejores modelos asuman el peso de los peores, lo que afecta su calidad al momento de promediar los resultados.

Además, esta variación se debe a que en los grupos resultantes, los modelos pueden estar distantes en términos de distancias, pero entre cortes mayores a 5, los grupos tendrán menos modelos para promediar. Además, los modelos que quedan en cada grupo serán más similares entre sí. Cabe destacar que cada modelo se construyó de manera diferente, como se especifica en el documento donde se obtuvieron las bases de datos utilizadas en este trabajo.

0.7. Recomedaciónes

Se sugiere adoptar un enfoque alternativo para llevar a cabo esta tarea. En lugar de utilizar exclusivamente SCE, se puede emplear la técnica de distancia. Esta técnica permite identificar los coeficientes que son más similares entre sí, es decir, aquellos que presentan una menor distancia. De este modo, se pueden comparar los resultados obtenidos en este trabajo con los obtenidos utilizando la técnica de distancia, y así obtener una perspectiva más completa.

0.8. Refencias

https://fhernanb.github.io/libro$_{m}od_{p}red/arb - de - regre.html$
https://aprendeia.com/arboles-de-decision-regresion-teoria-machine-learning/