PRESENTADO POR:

JUAN ESTEBAN RESTREPO JARAMILLO
JUAN DIEGO ESPINOSA HERNÁNDEZ
DANIEL CAMILO ATAPUMA
JOSÉ LUIS SUAREZ LEDESMA

UNIVERSIDAD NACIONAL DE COLOMBIA

TAREA
INTRODUCCIÓN AL ANÁLISIS DE SUPERVIVENCIA

DOCENTE:
JUAN CARLOS SALAZAR URIBE

2023

1 Ejercicio 1

a) Demostración.

Sea T una variable aleatoria continua con f.d.p $f(t;\theta)$ y en los R^+,cuya vida media está determinada por $E(T)$.

A partir de la definición de valor esperado se deduce que:

E(T) = $\int_0^\infty tf(t;\theta)dt = \int_0^\infty \int_0^t f(t;\theta)dxdt$
$= \int_0^\infty \int_x^\infty f(t;\theta)dtdx$ ($\triangle$)

Tenemos que,

$1 = \int_0^\infty f(t;\theta)dt = \int_0^x f(t;\theta)dt + \int_x^\infty f(t;\theta)dt$

Por lo que,

$\int_x^\infty f(t;\theta) = 1 - F(t;\theta)$, con $F(x;\theta)$ la f.d.a de T calculada en el x.

Al sustituir en ($\triangle$), se obtiene que.

$\int_0^\infty \int_x^\infty f(t;\theta)dtdx = \int_0^\infty [1 - F(x;\theta)]dx = \int_0^\infty [1 - F(t;\theta)]dt$

En consecuencia, si T es una variable aleatoria continua con f.d.p $f(t;\theta)$ y en los R^+ . Por consiguiente tenemos que.

$$E(T) = \int_0^\infty tf(t;\theta)dt = \int_0^\infty [1 - F(t;\theta)]dt$$

Punto b

simulamos en R 200 valores de una distribucion Weibull con shape=7.2393 y scale=12.3559.

```
library(MASS)
library(ggplot2)
set.seed(123)
# Generar 200 valores de la distribución Weibull
val_weibull <- rweibull(200, shape = 7.2393, scale = 12.3559)
```

```
df <- data.frame(val_weibull)
ggplot(df, aes(x = val_weibull)) +
  geom_histogram(binwidth = 0.5, fill = "blue", color = "black", alpha = 0.7) +
  labs(x = "Tiempo", y = "Frecuencia") +
  ggtitle("Simulación de la Distribución Weibull") +
  theme_minimal()
```

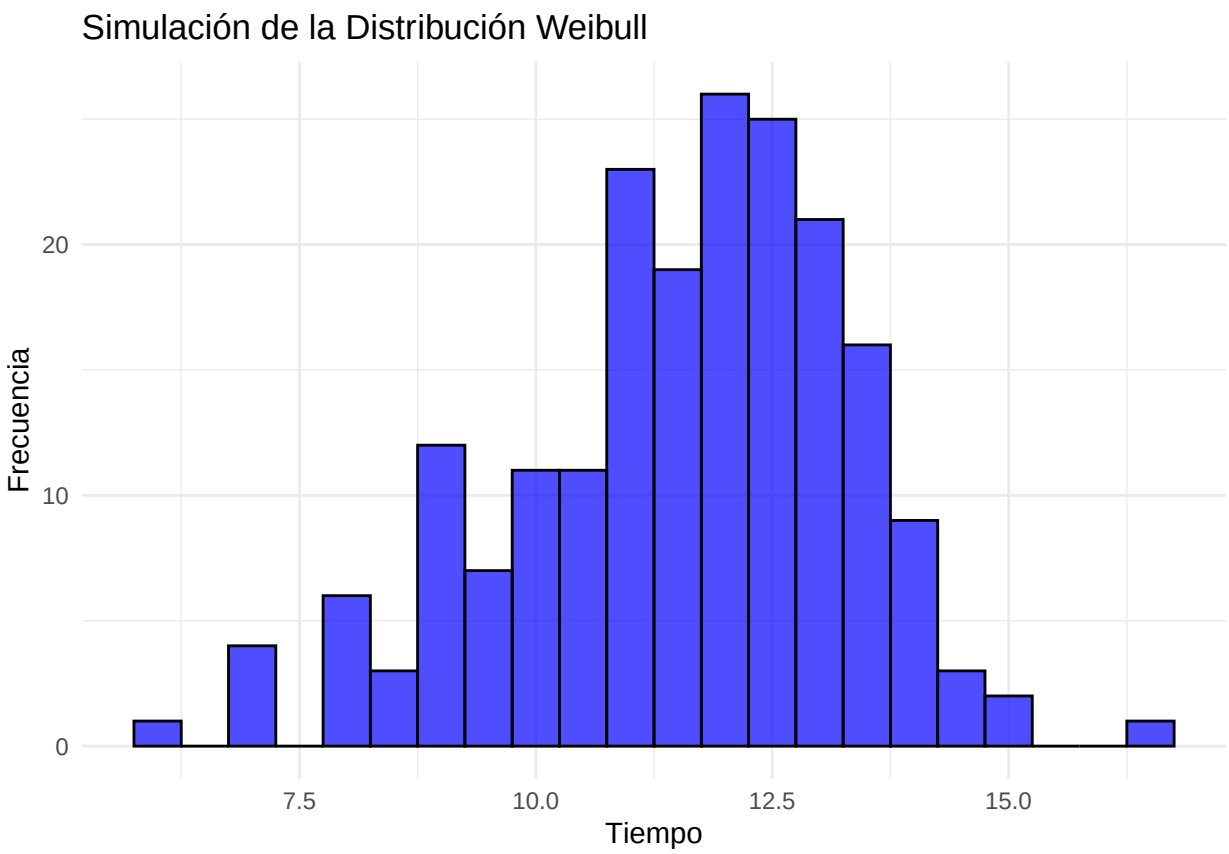

A partir de ello se halla las estimaciones de máxima verosimilitud para eta y beta con los valores simulados.

```
# Ajustar la distribución Weibull a los datos
ajuste <- fitdistr(val_weibull, densfun = "weibull")

# Obtener las estimaciones de máxima verosimilitud
eta <- ajuste$estimate["shape"]
beta <- ajuste$estimate["scale"]

# Imprimir los resultados
print( eta)
```

```
##    shape
## 7.773494
```

```r
print( beta)
```

```
##    scale
## 12.26651
```

Las estimaciones obtenidas para los parámetros de la distribución Weibull a partir de los valores simulados difieren ligeramente de los valores originales.

```r
f<-function(x){exp(-(x/eta)^beta) }
integrate(f, 0, Inf)
```

```
## 7.45529 with absolute error < 0.00062
```

El valor de la vida media 7.45529 se acerca al parametro shape de la distribucion.

```r
weibull<-val_weibull
mean(weibull)
```

```
## [1] 11.53872
```

El promedio aritmetico 11.53872 es un poco cercano al parametro scale de la Weibull con el que se hizo la simulacion.

En general hay una variabilidad significante entre los parametros que se utilizaron para simular y los que se calcularon, Esto puede deberse a la variabilidad de los datos simulados y a las limitaciones de la estimación de máxima verosimilitud. Para obtener estimaciones más precisas, sería recomendable aumentar el tamaño de la muestra.

Se tiene a disposición las observaciones de 418 pacientes relativos a la cirrosis biliar primaria. Estos datos provienen del ensayo de May Clinic sobre la enfermedad [PBC, por sus siglas en inglés] del hígado realizado entre 1974 y 1984. A cada paciente se le midieron 17 covariables relacionadas a diversas condiciones médicas. A continuación se presentan las primeras 5 variables de la base de datos.

Datos sobre cirrosis biliar primaria

Time	Status	Drug	Age	Sex
400	1	1	58.76523	1
4500	0	1	56.44627	1
1012	1	1	70.07255	0
1925	1	1	54.74059	1
1504	1	2	38.10541	1
1832	0	2	55.53457	1

En la base de datos, la variable "Triglycerides" tiene 136 valores faltantes de un total de 418 observaciones. Debido a que el conjunto de datos esta relacionado con un problema sanitario, no se recomienda utilizar metodos de imputacion para completar los datos faltantes. Por lo tanto, se utilizara la base de datos sin cambios para el analisis inferencial posterior.

Se realiza un analisis descriptivo de los datos para identificar las variables mas relevantes que explican el tiempo de falla. Se genera un histograma inicial del tiempo de falla para comprender su distribucion.

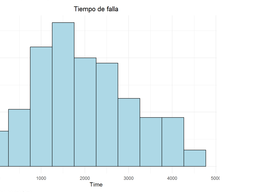

Distribución del tiempo de falla

Se observa asimetria positiva en los datos, indicando que la distribucion Weibull podria ajustarse bien al tempo de falla. Se realiza un analisis de correlacion entre las covariables numericas para identificar aquellas que mejor explican el tempo de falla y evitar la multicolinealidad.

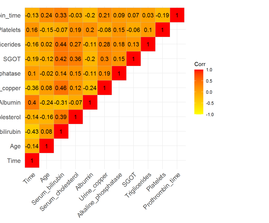

Correlación entre variables numéricas

En general, las variables muestran una baja correlacion lineal con el tempo de supervivencia. Sin embargo, esto no descarta la posibilidad de que exista alguna forma de asociacion (por ejemplo, cuadratica, logarítmica o exponencial) con la respuesta. La baja correlacion entre las covariables numericas es positiva, ya que indica que es poco probable que se presenten problemas de multicolinealidad.

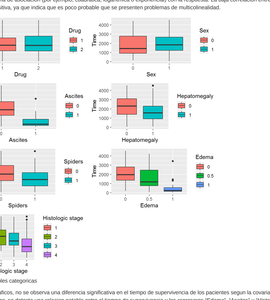

Análisis de variables categoricas

Al analizar los graficos, no se observa una diferencia significativa en el tempo de supervivencia de los pacientes segun la covariable "Drug" o "Sex". Sin embargo, se detecta una relacion notable entre el tempo de supervivencia y los regressores "Edema", "Ascites" y "Histologic Stage". Estos regressores parecen ser significativos para el modelo de regression.

Se ajusta un modelo Weibull parametrico con todas las covariables y se utiliza el metodo backward para eliminar aquellas que no son significativas en el tempo de falla. El proceso de seleccion de variables se resume en la siguiente tabla:

Selección de variables backward

Iteración	Covariable eliminada	Valor - P
1	Spiders	0.8302216
2	Triglycerides	0.7046547
3	Alkaline phosphatase	0.4947996
4	Ascites	0.8301095
5	Hepatomegaly	0.6558348
6	Platelets	0.3699826
7	Sex	0.1587183
8	Serum cholesterol	0.2108304

En el proceso de depuracion, se evaluo la covariable "Histologic stage" que tenia un valor P de 0.03132326, el cual es un valor polemico. Para tomar una decision, se compararon dos modelos utilizando el criterio de informacion de Akaike. El modelo que incluye "Histologic stage" mostro un AIC ligeramente menor, por lo que se decidio mantener esta variable en el modelo final.

Parámetros estimados del modelo Weibull

	Coeficiente estimado	Error estándar	Valor - P
Intercept	10.25084	1.21904	0.00000
Age	-0.00826	0.00563	0.14263
Edema0.5	-0.11794	0.17505	0.50047
Edema1	-0.54795	0.20083	0.00636
Serum_bilirubin	-0.05100	0.01073	0.00000
Albumin	0.37289	0.15378	0.01532
Urine_copper	-0.00212	0.00054	0.00010
SGOT	-0.00193	0.00102	0.05809
Prothrombin_time	-0.11698	0.06612	0.07686
Histologic_stage2	-0.87595	0.63925	0.17060
Histologic_stage3	-1.05420	0.62594	0.09214
Histologic_stage4	-1.34821	0.62622	0.03132
Log(scale)	-0.50259	0.07111	0.00000

Se ajusta un modelo semiparametrico de Cox para evitar suposiciones distribucionales en los tempos de falla. Se realiza la seleccion de variables de manera similar al modelo anterior. A continuacion, se resume el resultado de dicha seleccion:

Selección de variables backward Cox

Iteración	Covariable eliminada	Valor - P
1	Ascites	0.9058867
2	Alkaline phosphatase	0.4185727
3	Triglycerides	0.6634090
4	Spiders	0.9120573
5	Hepatomegaly	0.6459919
6	Platelets	0.4006652
7	Sex	0.1455790
8	Serum cholesterol	0.1799700

El modelo de Cox selecciono las mismas covariables que el modelo parametrico Weibull. Por lo tanto, ambos modelos comparten la misma estructura de regresores. A continuacion, se presentan los coeficientes estimados para el modelo de Cox:

Parámetros estimados del modelo de Cox

	Coeficiente estimado	Error estándar	Valor - P
Age	0.01261	0.00940	0.18000
Edema0.5	0.16555	0.29060	0.56890
Edema1	0.82542	0.34197	0.01579
Serum_bilirubin	0.08519	0.01893	0.00001
Albumin	-0.54255	0.26055	0.01366
Urine_copper	0.00340	0.00091	0.00020
SGOT	0.00294	0.00169	0.08151
Prothrombin_time	0.18207	0.10870	0.09393
Histologic_stage2	1.44596	1.04824	0.16776
Histologic_stage3	1.76473	1.02395	0.09481
Histologic_stage4	2.24389	1.02352	0.02836

Los parametros estimados en ambos modelos, Weibull y Cox, no se pueden comparar directamente debido a que estan en escalas diferentes: logaritmo del tempo de supervivencia y hazard, respectivamente. Es necesario aplicar una transformacion para hacer la comparacion adecuada.

	Weibull $log(T)$	Cox PH	$-\frac{1}{\gamma}\beta = 0.60496$
Age	-0.0062605	0.0126060	0.0136547
Edema0.5	-0.1179439	0.1655463	0.1949617
Edema1	-0.5479487	0.8254201	0.9057616
SerumBilirubin	-0.0509980	0.0851874	0.0842999
Albumin	0.3728857	-0.6425486	-0.6163817
UrineCopper	-0.0021183	0.0033968	0.0035015
SGOT	-0.0019271	0.0029423	0.0031855
ProthrombinTime	-0.1169786	0.1820710	0.1933662
HistologicStage2	-0.8759535	1.4459609	1.4479549
HistologicStage3	-1.0541988	1.7647303	1.7425952
HistologicStage4	-1.3482109	2.2438942	2.2285985

Los parametros estimados en terminos del hazard son considerablemente similares en ambos modelos, lo que indica un buen ajuste y especificacion.

Se desea investigar si las covariables "sex", "ascites" y "spiders" son significativas para explicar el tempo de supervivencia de los pacientes con cirrosis biliar primaria. Se ajustaron un modelo semiparametrico de Cox y un modelo parametrico Weibull para determinar la importancia de estos regresores. Los resultados se resumen en las siguientes tablas:

Parámetros modelo Weibull

	Coeficientes estimados	Error estándar	Valor - P
Intercept	8.13605	0.16730	0.00000
Sex1	0.39706	0.17882	0.02547
Ascites1	-1.42089	0.21301	0.00000
Spiders1	-0.58407	0.14509	0.00006
Log(scale)	-0.27332	0.07379	0.00021

Parámetros modelo de Cox

	Coeficientes estimados	Error estándar	Valor - P
Sex1	-0.49863	0.23075	0.03070
Ascites1	1.85362	0.27441	0.00000
Spiders1	0.78849	0.19019	0.00003

En base a las tablas anteriores, se puede observar que, utilizando un nivel de significancia de $\alpha = 0.05$ en ambos modelos, las tres covariables involucradas son significativas e importantes para explicar el tempo de supervivencia de los pacientes con cirrosis biliar primaria.

A continuacion, se presentan los graficos de supervivencia para cada modelo, mostrando el comportamiento de la respuesta (tiempo de supervivencia) en los diferentes niveles de las covariables:

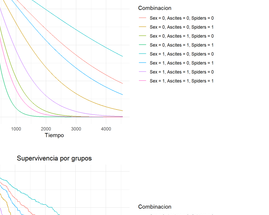

Modelo Weibull

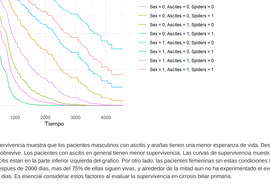

Modelo de Cox

El analisis de supervivencia muestra que los pacientes masculinos con ascitis y arañas tienen una menor esperanza de vida. Despues de 1000 dias, solo el 6% sobrevive. Los pacientes con ascitis en general tienen menor supervivencia. Las curvas de supervivencia muestran que los pacientes con ascitis estan en la parte inferior izquierda del grafico. Por otro lado, las pacientes femeninas sin estas condiciones tienen mayor supervivencia. Despues de 2000 dias, mas del 75% de ellas siguen vivas, y alrededor de la mitad aun no ha experimentado el evento de interes despues de 4000 dias. Es esencial considerar estos factores al evaluar la supervivencia en cirrosis biliar primaria.