Intro. Analisis de Supervivencia
Tarea 2

4.7

Por:

Daniela Pico

Juan Sebastián Falcón

Alexis Nieto

Entregado a:

Juan Carlos Salazar

Universidad Nacional de Colombia

Sede Medellín

Facultad de ciencias

1. (PRÁCTICO) Usando R o SAS y el conjunto de datos anexo (ovarian.csv) ajuste al menos tres modelos paramétricos de la familia AFT y seleccione uno de ellos de acuerdo a algún criterio estadístico de los vistos en clase. Inicialmente, debe usar todas las covariables, y secuencialmente y con cada distribución, seleccione las variables estadísticamente importantes de acuerdo a su valor-p. Una vez seleccione un modelo, evalúe posibles efectos confusores de las variables que no fueron incluidas en el modelo (si es que aplica) e interacciones. INTERPRETE.

La base de datos Ovarian, referente a datos de supervivencia al cáncer de ovario, está compuesta por 26 registros y un total de 6 varables:

- futimee: survival or censoring time (variable numérica)
- fustat: censoring (variable categórica de 2 niveles: 0 y 1)
- age: in years (variable numérica)
- resid.ds: residual disease present (1=no,2=yes) (variable categórica)
- rx: treatment group (variable categórica de dos niveles: 1 y 2)
- ecog.ps: ECOG performance status (1 is better, see reference) (variable categórica de dos niveles: 1 y 2)

A continuación se presenta el ajuste de 4 modelos de regresión paramétricos para la base de datos ovarian: modelo de regresión exponencial, modelo de regresión weibull, modelo de regresión lognormal, modelo de regresión log-logístico. Vale aclarar que R para las variables de caracter cualitativo toma como referencia el nivel de menor valor.

Modelo Exponencial	Value	Std. Error	z	p
(Intercept)	12.3913	2.0130	6.1558	0.0000
age	-0.0875	0.0338	-2.5897	0.0096
as.factor(resid.ds)2	-0.7659	0.7411	-1.0335	0.3014
as.factor(rx)2	0.6269	0.6162	1.0173	0.3090
as.factor(ecog.ps)2	-0.2523	0.6061	-0.4163	0.6772

Modelo Weibull	Value	Std. Error	z	p
(Intercept)	10.5648	1.1771	8.9757	0.0000
age	-0.0650	0.0194	-3.3563	0.0008
as.factor(resid.ds)2	-0.5210	0.3921	-1.3286	0.1840
as.factor(rx)2	0.5206	0.3244	1.6050	0.1085
as.factor(ecog.ps)2	-0.0668	0.3234	-0.2064	0.8365
Log(scale)	-0.6547	0.2399	-2.7289	0.0064

Modelo Lognormal	Value	Std. Error	z	p
(Intercept)	10.3932	0.9833	10.5699	0.0000
age	-0.0676	0.0163	-4.1515	0.0000
as.factor(resid.ds)2	-0.5331	0.3493	-1.5262	0.1270
as.factor(rx)2	0.6059	0.3027	2.0017	0.0453

Modelo Lognormal	Value	Std. Error	z	p
as.factor(ecog.ps)2	-0.0205	0.3203	-0.0640	0.9490
Log(scale)	-0.4590	0.2202	-2.0844	0.0371

Modelo Loglogístico	Value	Std. Error	z	p
(Intercept)	10.4756	1.0427	10.0463	0.0000
age	-0.0690	0.0174	-3.9708	0.0001
as.factor(resid.ds)2	-0.5469	0.3530	-1.5491	0.1214
as.factor(rx)2	0.5957	0.3039	1.9602	0.0500
as.factor(ecog.ps)2	-0.0346	0.3147	-0.1099	0.9125
Log(scale)	-0.9869	0.2412	-4.0908	0.0000

Las anteriores son las tablas resumen de cada uno de los modelos de regresión ajustados que ayuden a explicar el $log(futime)$, es decir, el logaritmo del tiempo de supervivencia al cáncer de ovario. Resulta curioso como para los primeros 2 modelos de regresión ajustados, exponencial y weibull, las 3 variables de caracter categóricas presentes resultan no ser estadísticamente significativas para explicar el log de la supervivencia; mientras que para los otros 2 modelos, lognormal y loglogístico, solo para la variable categórica **rx**, grupo de tratamiento (1 o 2), presenta una significancia estadística al límite que le permite ser considerada a la hora de explicar el log de la supervivencia al cáncer. De resto, la variable **age** es estadísticamente significativa en todos los modelos de regresión ajustados.

Lo siguiente es alegir uno de los modelos para seguir el análisis, las maneras para dar con la elección será respecto a los menores valores en los criterios de información AIC y BIC que se observen. Tales estadísticos se presentan a continuación:

Modelo de regresión	df	AIC
Exponencial	5	191.2886
Weibull	6	187.6942
Lognormal	6	**184.8166**
Loglogístico	6	185.6466

Modelo de regresión	df	BIC
Exponencial	5	197.5791
Weibull	6	195.2428
Lognormal	6	**192.3652**
Loglogístico	6	193.1952

Se observa que los modelos de regresión lognormal y loglogístico son los que presentan menores valores en AIC y BIC, y entre ellos la diferencia entre estos criterios no es mucha, pero será escogido el modelo de regresión lognormal por presentar los menores valores en estos estadísticos. Previamente se aplicó el método automático para la selección de variables Backward a cada modelo, en todos menos el modelo elegido se eliminaron todas las variables de tipo categóricas, es decir: **resid.ds**, **rx** y **ecog.ps**; quedando esos modelos solo con presencia de la variable numérica **age**. Para el modelo lognormal quedaron incluidas las variables **rx**, con nivel de referencia 1, y **age**. A continuación se presenta un resumen para todos los modelos:

- **Backward para modelo exponencial**: primera variable eliminada: ecog.ps nivel de referencia 1, valor-p=0.6772; segunda variable eliminada: resid.ds nivel de referencia 1, valor-p=0.3395; tercera variable eliminada: rx nivel de referencia 1, valor-p=0.28310. Quedan variable age con un valor-p=0.00047

e intercepto también estadísticamente significativo para explicar el log del tiempo de supervivencia al cáncer de ovario.

- **Backward para modelo weibull**: primera variable eliminada: ecog.ps nivel de referencia 1, valor-p=0.83646; segunda variable eliminada: resid.ds nivel de referencia 1, valor-p=0.1879; tercera variable eliminada: rx nivel de referencia 1, valor-p=0.096. Quedan variable age con un valor-p=4.9e-05 e intercepto también estadísticamente significativo para explicar el log del tiempo de supervivencia al cáncer de ovario.

- **Backward para modelo lognormal**: primera variable eliminada: ecog.ps nivel de referencia 1, valor-p=0.949; segunda variable eliminada: resid.ds nivel de referencia 1, valor-p=0.110. Quedan variable age con un valor-p=7.4e-06, varible categórica rx con nivel de referencia 1 y valor-p=0.029 e intercepto también estadísticamente significativo para explicar el log del tiempo de supervivencia al cáncer de ovario.

- **Backward para modelo loglogístico**: primera variable eliminada: ecog.ps nivel de referencia 1, valor-p=0.91; segunda variable eliminada: resid.ds nivel de referencia 1, valor-p=0.11; tercera variable eliminada: rx nivel de referencia 1, valor-p=0.07309. Quedan variable age con un valor-p=7.9e-05 e intercepto también estadísticamente significativo para explicar el log del tiempo de supervivencia al cáncer de ovario.

Siguiendo con el análisis ahora se estudiarán posibles efectos confusores de las variable que no fueron incluidas en el modelo de regresión lognormal. Se obtienen las siguientes tablas:

Covariable	Estimación sin ecog.ps	Estimación con ecog.ps	Cambio porcentual
age	-0.0765	-0.0769	$\frac{\lvert -0.0765+0.0769\rvert}{\lvert -0.0769\rvert} * 100 =$ 0.52%
rx	0.6904	0.6677	$\frac{\lvert 0.6904-0.6677\rvert}{\lvert 0.6677\rvert} * 100 =$ 3.40%

Puesto que el cambio porcentual en las estimaciones de ambos parámetros después de considerar el efecto de ecog.ps no es mayor al 10% se puede argumentar que ecog.ps no es una variable de confusión.

Covariable	Estimación sin resid.ds	Estimación con resid.ds	Cambio porcentual
age	-0.0765	-0.0677	$\frac{\lvert -0.0765+0.0677\rvert}{\lvert -0.0677\rvert} * 100 =$ 12.99%
rx	0.6904	0.6030	$\frac{\lvert 0.6904-0.6030\rvert}{\lvert 0.6030\rvert} * 100 =$ 14.49%

Puesto que el cambio porcentual en las estimaciones de ambos parámetros después de considerar el efecto de resid.ds es mayor al 10% se puede argumentar que resid.ds es una variable de confusión. Por lo tanto se tiene que incluir a la variable resid.ds dentro del modelo.

De esta forma, el modelo de regresión lognormal final para explicar el log de la supervivencia al cáncer de ovario se presenta en la siguiente tabla resumen:

Modelo de regresión	Value	Std. Error	z	p
(Intercept)	10.3867	0.9756	10.6463	0.0000
age	-0.0677	0.0161	-4.2036	0.0000
as.factor(resid.ds)2	-0.5258	0.3288	-1.5992	0.1098

Modelo de regresión	Value	Std. Error	z	p
as.factor(rx)2	0.6030	0.2984	2.0206	0.0433
Log(scale)	-0.4609	0.2178	-2.1159	0.0344

2). Los siguientes datos se refieren a dos grupos de mujeres con cancer de ovario. En total hay 34 mujeres. Cada numero representa el progreso de la enfermedad en dias. El simbolo + representa el dato censurado

Grupo 1 (Tumor de Bajo grado): 28, 89, 175, 195, 309, 377+, 393+, 421+, 447+, 462, 709+, 744+, 770+, 1106+, 1206+

Grupo 2 (Tumor de alto grado): 34, 88, 137, 199, 280, 291, 299+, 300+, 309, 351, 358, 369, 369, 370, 375, 382, 429+, 451, 1119+

a) Ajuste un modelo Weibull a estos datos considerando como variable independiente la variable grupo que este caso tiene dos niveles: 1 y 2. Usando las repectivas estimaciones Gráfique la función Hazard. Interprete

h(t) ✓ (no H(t))

```
##
## Call:
## survreg(formula = Surv(dias, status) ~ as.factor(grupo), data = bd_cancer,
##     dist = "weibull")
##                     Value Std. Error     z      p
## (Intercept)         7.008      0.348 20.16 <2e-16
## as.factor(grupo)2 -0.941      0.407 -2.31  0.021
## Log(scale)        -0.195      0.181 -1.08  0.280
##
## Scale= 0.823
##
## Weibull distribution
## Loglik(model)= -154.3   Loglik(intercept only)= -157.3
##  Chisq= 6.03 on 1 degrees of freedom, p= 0.014
## Number of Newton-Raphson Iterations: 5
## n= 34
```

Respecto al valor-p= 0.014 obtenido con R que está asociado con el Deviance y en este caso se puede decir que el Modelo Weibull ajusta medianamente bien. En realidad D=2 x {157.3-154.3} = 6}.

El valor de scale = 0.823 como está entre 0.5 y 1 permite intuir que el hazard es creciente en una tasa decreciente; El signo negativo de la estimacion en grupo indica que estar en el grupo 2 representa una disminucion en el log de la supervivencia y por tanto incrementa el log del hazard.

De acuerdo a los valores de W. Para Grupo:

$$(\frac{-0.941}{0.407})^2 = 5.3455$$

Se pedían las curvas de h(t) no de H(t)

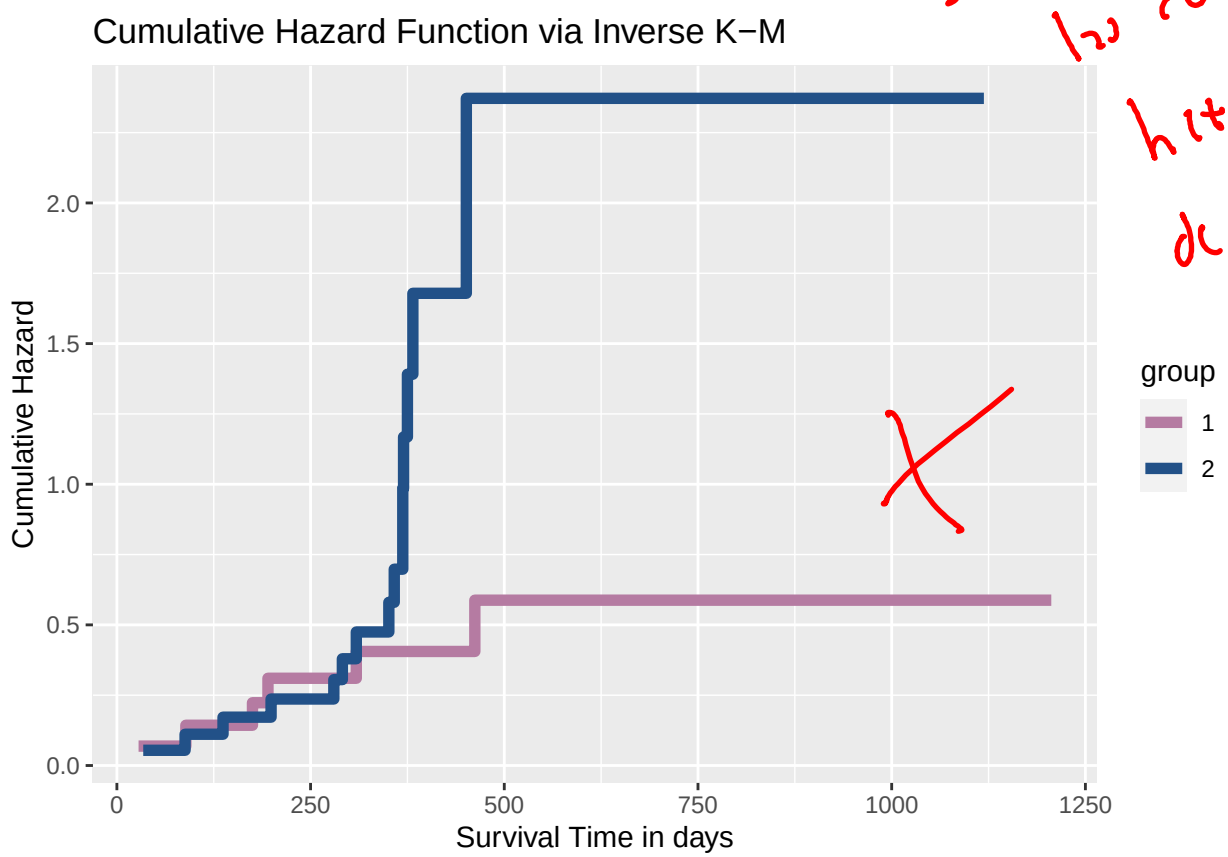

En la grafica del Hazard acumulado se observa el potencial de fallo instantaneo acumulado a medida que pasa el tiempo, por ello en el primer tiempo este valor es muy bajo, pues hay muy poco potencial de que alguno de los pacientes se muera. Sin embargo se observa desde los primeros meses, este potencial instantaneo crece rapidamente para el grupo 2 en comparacion con el grupo 1, además esto evidencia que lo idenficado en el ajuste del modelo Waibull se cumple.

b) Con estos datos sin usar Log Rank test prueba la hipotesis $H_0 : S_1(t) = S_2(t)$ para todo t. Use un $\alpha = 0.05$ ¿Qué se puede concluir?

Del ajuste del modelo Weibull se obtiene un valor p = 0.021, como 0.021<0.05 se rechaza la hipotesis nula y se concluye que $S_1(t) \neq S_2(t)$ ya que hay evidencia suficiente para afirmar que el grupo 2 tiene una diferencia significativa en el log de la supervivencia en comparación con el grupo 1

3. Suponga que una unidad puede fallar por dos causas. Por ejemplo, una persona puede morir ya sea por una enfermedad del corazón o por una enfermedad de riñón. Sean Y_1 = Tiempo de supervivencia con enfermedad del corazón y Y_2 = Tiempo de supervivencia con enfermedad del riñón. La pregunta de interés es ¿Cuál de las dos enfermedades causarán primero la muerte a un paciente?. Sea $T = mín(Y_1, Y_2)$. Suponga que $Y_1 \sim exp(\lambda_1)$ y $Y_2 \sim exp(\lambda_2)$ y que Y_1 y Y_2 son independientes. Bajo estas condiciones halle la f.d.p de la v.a. T. ¿Qué se puede decir del hazard de T?

Sea $F(t)$ la distribución acumulada de la variable aleatoria $T = mín(Y_1, Y_2)$. Por lo tanto,

$$F(t) = P(T < t) = P(min(Y_1, Y_2) < t)$$

Como Y_1 y Y_2 son variables aleatorias exponenciales independientes la anterior expresión por facilidad se puede escribir en términos del complemento de la distribución acumulada, es decir,

$$F(t|\lambda_1, \lambda_2) = P(T < t) = 1 - P(min(Y_1, Y_2) > t) = ...$$

$$... = 1 - P(Y_1 > t)P(Y_2 > t) = 1 - e^{-\lambda_1 t}e^{-\lambda_2 t}$$

De esta forma, la función de distribución acumulada asociada a T es $F(t|\lambda_1, \lambda_2) = 1 - e^{-(\lambda_1+\lambda_2)t}$, que es una acumulada exponencial. Ahora se procede a obtener a la f.d.p. $f(t|\lambda_1, \lambda_2)$ de T como sigue,

$$f(t|\lambda_1, \lambda_2) = \frac{dF(t|\lambda_1, \lambda_2)}{dt} = (\lambda_1 + \lambda_2)e^{-(\lambda_1+\lambda_2)t}$$

De esta forma se llega a que la función de densidad de probabilidad de T es también una distribución exponencial, es decir, $T = min(Y_1, Y_2) \sim exp(\lambda_1 + \lambda_2)$.

Continuando con el ejercicio, lo siguiente es obtener la función de riesgo para T. Se procede así,

$$h(t|\lambda_1, \lambda_2) = \frac{f(t|\lambda_1, \lambda_2)}{1 - F(t|\lambda_1, \lambda_2)} = \frac{(\lambda_1 + \lambda_2)e^{-(\lambda_1+\lambda_2)t}}{1 - (1 - e^{-(\lambda_1+\lambda_2)t})} = ...$$

$$... = \frac{(\lambda_1 + \lambda_2)e^{-(\lambda_1+\lambda_2)t}}{e^{-(\lambda_1+\lambda_2)t}} = (\lambda_1 + \lambda_2)$$

Dado que se encontró que la variable aleatoria T distribuye exponencialmente es de esperar que la función hazard $h(t|\lambda_1, \lambda_2)$ sea constante y equivalente al parámetro de la distribución asociada a T, es decir, $(\lambda_1+\lambda_2)$.

4) Pruebe lo siguiente si logT ~ normal(μ, σ) entonces T ~ lognormal(μ, σ).

Para probar la anterior afirmacion estableceremos que

Sea $Y = T$, entonces $Log(Y) = Log(T)$, Luego $\frac{dLog(T)}{dY} = \frac{1}{Y}$

Teniendo en cuenta que

$$f(Log(T)) = \frac{1}{\sigma\sqrt{2\pi}}exp(-\frac{(ln(T) - \mu)^2}{2\sigma^2})$$

Para t>0.

Luego, por teorema de cambio de variable

$$g(Y) = f(Log(Y))|\frac{dLog(T)}{dY}|$$

$$\frac{1}{\sigma\sqrt{2\pi}}exp(-\frac{(ln(Y)-\mu)^2}{2\sigma^2})|\frac{1}{Y}|$$

$$\frac{1}{Y\sigma\sqrt{2\pi}}exp(-\frac{(ln(Y)-\mu)^2}{2\sigma^2})$$

Por ende se prueba que $Y \sim LogNormal(\mu.\sigma)$, es decir $T \sim LogNormal(\mu.\sigma)$

5). Pruebe que si T~lognormal(μ, σ) entonces log T ~ normal(μ, σ)

Prueba: Sea $Y = log(T)$, entonces $e^y = T$ y $\frac{dt}{dy} = e^y$. Como $f(t) = \frac{1}{t\sigma\sqrt{2\pi}}exp(-\frac{(ln(t)-\mu)^2}{2\sigma^2})$ para t>0, usando la tecnica de cambio de variable:

$$g(y) = f(e^y)|e^y|$$
$$= \frac{1}{e^y\sigma\sqrt{2\pi}}exp(-\frac{(y-\mu)^2}{2\sigma^2})e^y$$
$$= \frac{1}{\sigma\sqrt{2\pi}}exp(-\frac{(y-\mu)^2}{2\sigma^2})$$

Por lo que Y ~ Normal (μ, σ)

6) Pruebe lo siguiente si T ~ loglogis(μ, σ) entonces log T ~ logis(μ, σ).

Sea $Y = Log(T)$, entonces $e^Y = T$, Luego $\frac{dT}{dY} = e^Y$

Teniendo en cuenta que

$$f(T) = \frac{1}{\sigma T}\frac{e^{\frac{log(T)-\mu}{\sigma}}}{[1+e^{\frac{log(T)-\mu}{\sigma}}]^2}$$

Para t>0.

Luego, por teorema de cambio de variable

$$g(Y) = f(e^Y)|e^Y|$$

$$\frac{1}{\sigma e^Y}\frac{e^{\frac{log(e^Y)-\mu}{\sigma}}}{[1+e^{\frac{log(e^Y)-\mu}{\sigma}}]^2}|e^Y|$$

$$\frac{1}{\sigma}\frac{e^{\frac{Y-\mu}{\sigma}}}{[1+e^{\frac{Y-\mu}{\sigma}}]^2}$$

Por ende se prueba que $Y \sim Logis(\mu.\sigma)$, es decir $Log(T) \sim Logis(\mu.\sigma)$

7. Pruebe lo siguiente si $logT \sim logis(\mu, \sigma)$ entonces $T \sim loglogis(\mu, \sigma)$.

Sea $Y = log(T)$, entonces $\frac{dY}{dt} = \frac{1}{t}$. De esta forma,

$$g(t) = f(y) \times |\frac{dY}{dt}| = \frac{1}{\sigma} \frac{e^{\frac{y-\mu}{\sigma}}}{\left[1 + e^{\frac{y-\mu}{\sigma}}\right]^2} \frac{1}{t} = ...$$

$$... = \frac{1}{\sigma t} \frac{e^{\frac{log(t)-\mu}{\sigma}}}{\left[1 + e^{\frac{log(t)-\mu}{\sigma}}\right]^2}$$

Esta expresión resultado corresponde una p.d.f. log-logística asociada entonces T, demostrando así que si $logT \sim logis(\mu, \sigma)$, entonces $T \sim loglogis(\mu, \sigma)$.