PRESENTADO POR:

JUAN ESTEBAN RESTREPO JARAMILLO
JUAN DIEGO ESPINOSA HERNÁNDEZ
DANIEL CAMILO ATAPUMA
JOSÉ LUIS SUAREZ LEDESMA

UNIVERSIDAD NACIONAL DE COLOMBIA

TAREA
INTRODUCCIÓN AL ANÁLISIS DE SUPERVIVENCIA

DOCENTE:
JUAN CARLOS SALAZAR URIBE

2023

1. (PRACTICO) Usando R o SAS y el conjunto de datos anexo (ovarian.csv) ajuste al menos tres modelos paramétricos de la familia AFT y seleccione uno de ellos de acuerdo con algún criterio estadístico de los vistos en clase. Inicialmente, debe usar todas las covariables, y secuencialmente y con cada distribución, seleccione las variables estadísticamente importantes de acuerdo con su valor-p. INTERPRETE.

Solución:

Usando R se ajustan 4 modelos paramétricos de la familia AFT y se obtienen los siguientes resultados:

```r
library(survival)
library(splines)
library(MASS)
library(readxl)
df <- read_csv("C:/Users/jose.suarez/Downloads/ovarian.csv")
Exponencial1 <- survreg(Surv(futime, fustat)~ age + factor(resid.ds)+ factor(rx)+
factor(ecog.ps), data = df, dist = "exponential")

Weibull <- survreg(Surv(futime, fustat)~ age + factor(resid.ds)+ factor(rx)+
factor(ecog.ps), data = df, dist = "weibull")

Lognorm1 <- survreg(Surv(futime, fustat)~ age + factor(resid.ds)+ factor(rx)+
factor(ecog.ps), data = df, dist = "lognormal")

Loglogis1 <- survreg(Surv(futime, fustat)~ age + factor(resid.ds)+ factor(rx)+
factor(ecog.ps), data = df, dist = "loglogis")
```

Modelo exponencial

```
Call:
survreg(formula = Surv(futime, fustat) ~ age + factor(resid.ds) +
    factor(rx) + factor(ecog.ps), data = df, dist = "exponential")
                    Value Std. Error     z       p
(Intercept)       12.3913     2.0130  6.16 7.5e-10
age               -0.0875     0.0338 -2.59  0.0096
factor(resid.ds)2 -0.7659     0.7411 -1.03  0.3014
factor(rx)2        0.6269     0.6162  1.02  0.3090
factor(ecog.ps)2  -0.2523     0.6061 -0.42
Call:
survreg(formula = Surv(futime, fustat) ~ age + factor(resid.ds) +
    factor(rx) + factor(ecog.ps), data = df, dist = "exponential")
                    Value Std. Error     z       p
(Intercept)       12.3913     2.0130  6.16 7.5e-10
age               -0.0875     0.0338 -2.59  0.0096
factor(resid.ds)2 -0.7659     0.7411 -1.03  0.3014
factor(rx)2        0.6269     0.6162  1.02  0.3090
factor(ecog.ps)2  -0.2523     0.6061 -0.42  0.6772

Scale fixed at 1

Exponential distribution
Loglik(model)= -90.6   Loglik(intercept only)= -98  0.6772

Scale fixed at 1

Exponential distribution
Loglik(model)= -90.6   Loglik(intercept only)= -98
        Chisq= 14.78 on 4 degrees of freedom, p= 0.0052
Number of Newton-Raphson Iterations: 5
n= 26
```

Los resultados muestran que, para este modelo con un nivel de significancia de 0.05, se identifica que la única variable con un valor p menor que 0.05 y, por lo tanto, estadísticamente significativa, es la variable age.

Modelo Weibull

```
Call:
survreg(formula = Surv(futime, fustat) ~ age + factor(resid.ds) +
    factor(rx) + factor(ecog.ps), data = df, dist = "weibull")
                    Value Std. Error     z       p
(Intercept)       10.5648     1.1771  8.98 < 2e-16
age               -0.0650     0.0194 -3.36 0.00079
factor(resid.ds)2 -0.5210     0.3921 -1.33 0.18398
factor(rx)2        0.5206     0.3244
Call:
survreg(formula = Surv(futime, fustat) ~ age + factor(resid.ds) +
    factor(rx) + factor(ecog.ps), data = df, dist = "weibull")
                    Value Std. Error     z       p
(Intercept)       10.5648     1.1771  8.98 < 2e-16
age               -0.0650     0.0194 -3.36 0.00079
factor(resid.ds)2 -0.5210     0.3921 -1.33 0.18398
factor(rx)2        0.5206     0.3244  1.60 0.10850
factor(ecog.ps)2   1.60 0.10850
factor(ecog.ps)2  -0.0668     0.3234 -0.21 0.83646
Log(scale)        -0.6547     0.2399 -2.73 0.00635

Scale= 0.52

Weibull distribution
Loglik(model)= -87.8 -0.0668     0.3234 -0.21 0.83646
Log(scale)        -0.6547     0.2399 -2.73 0.00635

Scale= 0.52

Weibull distribution
Loglik(model)= -87.8   Loglik(intercept only)= -98
        Chisq= 20.21 on 4 degrees of freedom, p= 0.00045
Number of Newton-Raphson Iterations: 6
n= 26
```

Los resultados muestran que, para este modelo con un nivel de significancia de 0.05, se identifica que la única variable con un valor p menor que 0.05 y, por lo tanto, estadísticamente significativa, es la variable age.

Modelo Log-normal

```
Call:
survreg(formula = Surv(futime, fustat) ~ age + factor(resid.ds) +
    factor(rx) + factor(ecog.ps), data = df, dist = "lognormal")
                    Value Std. Error     z       p
(Intercept)       10.3932     0.9833 10.57 < 2e-16
age               -0.0676     0.0163 -4.15
Call:
survreg(formula = Surv(futime, fustat) ~ age + factor(resid.ds) +
    factor(rx) + factor(ecog.ps), data = df, dist = "lognormal")
                    Value Std. Error     z       p
(Intercept)       10.3932     0.9833 10.57 < 2e-16
age               -0.0676     0.0163 -4.15 3.3e-05
factor(resid.ds)2 -0.5331     0.3493 -1.53   0.127
factor(rx)2        0.6059     0.3027  2.00   0.045
factor(ecog.ps)2  -0.0205     0.3203 -0.06   0.949
Log(scale)        -0.4590     0.2202 3.3e-05
factor(resid.ds)2 -0.5331     0.3493 -1.53   0.127
factor(rx)2        0.6059     0.3027  2.00   0.045
factor(ecog.ps)2  -0.0205     0.3203 -0.06   0.949
Log(scale)        -0.4590     0.2202 -2.08   0.037

Scale= 0.632

Log Normal distribution
Loglik(model)= -86.4   Loglik(intercept only)= -97.1
        Chisq= 21.43  -2.08   0.037
```

Los resultados revelan que, al considerar un nivel de significancia de 0.05, se constata que las variables age y rx = 2 son las únicas que muestran una relevancia estadística, ya que sus valores p son inferiores al umbral establecido.

Modelo Log-logístico

```
Call:
survreg(formula = Surv(futime, fustat) ~ age + factor(resid.ds) +
    factor(rx) + factor(ecog.ps), data = df, dist = "loglogis")
                    Value Std. Error
Call:
survreg(formula = Surv(futime, fustat) ~ age + factor(resid.ds) +
    factor(rx) + factor(ecog.ps), data = df, dist = "loglogis")
                     Value Std. Error     z       p
(Intercept)        10.4756     1.0427 10.05 < 2e-16
age                -0.0690     0.0174 -3.97 7.2e-05
factor(resid.ds)2 -0.5469     0.3530 -1.55    0.12
factor(rx)2         0.5957     0.3039  1.96    0.05
factor(ecog.ps)2  -0.0346     0.3147 -0.11    0.91
Log(scale)         -0.9869     0.2412 -4.09 4.3e-05

Scale= 0.373       z       p
(Intercept)        10.4756     1.0427 10.05 < 2e-16
age                -0.0690     0.0174 -3.97 7.2e-05
factor(resid.ds)2 -0.5469     0.3530 -1.55    0.12
factor(rx)2         0.5957     0.3039  1.96    0.05
factor(ecog.ps)2  -0.0346     0.3147 -0.11    0.91
Log(scale)         -0.9869     0.2412 -4.09 4.3e-05

Scale= 0.373

Log logistic distribution
Loglik(model)= -86.8   Loglik(intercept only)= -97.4
        Chisq= 21.06 on 4 degrees of freedom, p= 0.00031
Number of Newton-Raphson Iterations: 6
```

Los resultados revelan que, al considerar un nivel de significancia de 0.05, se constata que las variables age y rx = 2 son las únicas que muestran una relevancia estadística, ya que sus valores p son inferiores al umbral establecido

Posteriormente, se procede a realizar una nueva adaptación de los 4 modelos, esta vez utilizando exclusivamente las variables que previamente se han identificado como significativas.

```
Exponencial2 <- survreg(Surv(futime, fustat)~ age, data = df, dist = "exponential")
Weibull2 <- survreg(Surv(futime, fustat)~ age, data = df, dist = "weibull")
Lognorm2 <- survreg(Surv(futime, fustat)~ age + factor(rx), data = df, dist = "lognormal")
Loglogis1 <- survreg(Surv(futime, fustat)~ age + factor(rx), data = df, dist = "loglogis")
```

Se comparan los modelos usando el AIC y el BIC:

AIC

Modelo con todas las variables

```
AIC(Exponencial1, Weibull, Lognorm1, Loglogis1)
```

	df <dbl>	AIC <dbl>
Exponencial1	5	191.2886
Weibull	6	187.6942
Lognorm1	6	184.8166
Loglogis1	6	185.6466

Modelo con variables significativas

```
AIC(Exponencial2, Weibull2, Lognorm2, Loglogis2)
```

	df <dbl>	AIC <dbl>
Exponencial2	2	187.5586
Weibull2	3	186.0025
Lognorm2	4	183.3164
Loglogis2	4	184.0863

BIC

Modelo con todas las variables

```
BIC(Exponencial1, Weibull, Lognorm1, Loglogis1)
```

	df <dbl>	BIC <dbl>
Exponencial1	5	197.5791
Weibull	6	195.2428
Lognorm1	6	192.3652
Loglogis1	6	193.1952

Modelo con variables significativas

```
BIC(Exponencial2, Weibull2, Lognorm2, Loglogis2)
```

	df <dbl>	BIC <dbl>
Exponencial2	2	190.0748
Weibull2	3	189.7768
Lognorm2	4	188.3488
Loglogis2	4	189.1186

Al analizar los resultados, se nota que, al utilizar únicamente las variables significativas en cada modelo, se produce una reducción en los valores de AIC y BIC. Es importante destacar que, independientemente del modelo (con todas las variables o solo con las variables significativas) y del criterio utilizado (AIC o BIC), el modelo Log-Normal se destaca como el mejor modelo.

```
Call:
survreg(formula = Surv(futime, fustat) ~ age + factor(rx), data = df,
    dist = "lognormal")
              Value Std. Error     z       p
(Intercept) 10.5449     1.0482 10.06 < 2e-16
age         -0.0765     0.0171 -4.48
Call:
survreg(formula = Surv(futime, fustat) ~ age + factor(rx), data = df,
    dist = "lognormal")
              Value Std. Error     z       p
(Intercept) 10.5449     1.0482 10.06 < 2e-16
age         -0.0765     0.0171 -4.48 7.4e-06
factor(rx)2  0.6904     0.3169  2.18   0.029
Log(scale)  -0.3813     0.2189 -1.74   0.082

Scale= 0.683
```

El modelo utilizado revela una relación significativa entre las variables age y rx con el logaritmo de la supervivencia. Además, se identifica que la variable age tiene una asociación negativa en cuanto a su sentido.

Continuando con el análisis, se procederá a examinar posibles factores de confusión de las variables que no fueron consideradas en el modelo de regresión log-normal.

```
Lognorm3 <- survreg(Surv(futime, fustat)~ age + factor(resid.ds)+ factor(rx), data = df,
dist = "lognormal")
```

```
summary(Lognorm3)
```

```
Call:
survreg(formula = Surv(futime, fustat) ~ age + factor(resid.ds) +
    factor(rx), data = df, dist = "lognormal")
                    Value Std. Error     z       p
(Intercept)       10.3867     0.9756 10.65 < 2e-16
age               -0.0677     0.0161 -4.20 2.6e-05
factor(resid.ds)2 -0.5258     0.3288
Call:
survreg(formula = Surv(futime, fustat) ~ age + factor(resid.ds) +
    factor(rx), data = df, dist = "lognormal")
                    Value Std. Error     z       p
(Intercept)       10.3867     0.9756 10.65 < 2e-16
age               -0.0677     0.0161 -4.20 2.6e-05
factor(resid.ds)2 -0.5258     0.3288 -1.60   0.110
factor(rx)2        0.6030     0.2984  2.02   0.043
Log(scale)        -0.4609     0.2178 -2.12   0.034

Scale=  -1.60   0.110
factor(rx)2        0.6030     0.2984  2.02   0.043
Log(scale)        -0.4609     0.2178 -2.12   0.034

Scale= 0.631

Log Normal distribution
Loglik(model)= -86.4   Loglik(intercept only)= -97.1
        Chisq= 21.42 on 3 degrees of freedom, p= 8.6e-05
Number of Newton-Raphson Iterations:0.631
```

Covariable Estimación sin **resid.ds**

age= -0.0765

rx = 0.6904

Covariable Estimación con **resid.ds**

age= -0.0677

rx = 0.6030

Cambio porcentual

age = (|-0.0765+0.0677|/|-0.0677|)*100 = 12.99%

rx (|0.6904+0.6030|/|0.6030|)*100 = 14.49%

```
Lognorm4 <- survreg(Surv(futime, fustat)~ age + factor(rx)+ factor(ecog.ps), data = df,
dist = "lognormal")
```

```
summary(Lognorm4)
```

```
Call:
survreg(formula = Surv(futime, fustat) ~ age + factor(rx) + factor(ecog.ps),
    data = df, dist = "lognormal")
                   Value Std. Error     z       p
(Intercept)      10.5093     1.0370 10.13 < 2e-16
age              -0.0769     0.0169 -4.55 5.5e-06
factor(rx)2       0.6677     0.3169  2.11
Call:
survreg(formula = Surv(futime, fustat) ~ age + factor(rx) + factor(ecog.ps),
    data = df, dist = "lognormal")
                   Value Std. Error     z       p
(Intercept)      10.5093     1.0370 10.13 < 2e-16
age              -0.0769     0.0169 -4.55 5.5e-06
factor(rx)2       0.6677     0.3169  2.11   0.035
factor(ecog.ps)2  0.1159     0.3186  0.36   0.716
Log(scale)       -0.3966     0.2214 -1.79   0.073

Scale= 0.673

Log Normal distribution
Loglik(model)= -87.6   Loglik(intercept only)= -97.1
        Chisq= 19.06 on 3    0.035
factor(ecog.ps)2  0.1159     0.3186  0.36   0.716
Log(scale)       -0.3966     0.2214 -1.79   0.073

Scale= 0.673

Log Normal distribution
Loglik(model)= -87.6   Loglik(intercept only)= -97.1
        Chisq= 19.06 on 3 degrees of freedom, p= 0.00027
Number of Newton-Raphson Iterations: 6
n= 26
```

Covariable Estimación sin **ecog.ps**

age= -0.0765

rx = 0.6904

Covariable Estimación con **ecog.ps**

age= -0.0769

rx = 0.6677

Cambio porcentual

(|-0.0765+0.0769|/|-0.0765|)*100= 0.52%

(|0.6904-0.6677|)*100=3.4%

Dado que el porcentaje de cambio en las estimaciones de ambos parámetros después de considerar el efecto de resid.ds supera el 10%, se puede concluir que resid.ds actúa como una variable de confusión. Por lo tanto, se debe incluir la variable resid.ds en el modelo.

Así, se presenta el modelo final de regresión lognormal que explica el logaritmo de la supervivencia al cáncer de ovario en la siguiente formulación.

```
survreg(formula = Surv(futime, fustat) ~ age + factor(resid.ds) +
    factor(rx), data = df, dist = "lognormal")
                    Value Std. Error     z       p
(Intercept)       10.3867     0.9756 10.65 < 2e-16
age               -0.0677     0.0161 -4.20 2.6e-05
factor(resid.ds)2 -0.5258     0.3288 -1.60   0.110
factor(rx)2        0.6030     0.2984  2.02   0.043
Log(scale)        -0.4609     0.2178 -2.12   0.034

Scale=  -1.60   0.110
factor(rx)2        0.6030     0.2984  2.02   0.043
Log(scale)        -0.4609     0.2178 -2.12   0.034

Scale= 0.631

Log Normal distribution
Loglik(model)= -86.4   Loglik(intercept only)= -97.1
        Chisq= 21.42 on 3 degrees of freedom, p= 8.6e-05
Number of Newton-Raphson Iterations:0.631
```

2. (PRACTICO) Los siguientes datos se refieren a dos grupos de mujeres con cancer de ovario. En total hay 34 mujeres. Cada numero representa el tiempo de progreso de la enfermedad en dias. El sımbolo + representa un dato censurado

a) Ajuste un modelo Weibull a estos datos considerando como variable independiente la variable grupo que este caso tiene dos niveles: 1 y 2. Usando las repectivas estimaciones Gráfique la función Hazard. Interprete

```
##
## Call:
## survreg(formula = Surv(days, status) ~ as.factor(group), data = ov,
##     dist = "weibull")
##                     Value Std. Error     z      p
## (Intercept)         7.008      0.348 20.16 <2e-16
## as.factor(group)2 -0.941      0.407 -2.31  0.021
## Log(scale)        -0.195      0.181 -1.08  0.280
##
## Scale= 0.823
##
## Weibull distribution
## Loglik(model)= -154.3   Loglik(intercept only)= -157.3
##  Chisq= 6.03 on 1 degrees of freedom, p= 0.014
## Number of Newton-Raphson Iterations: 5
## n= 34
```

Respecto al valor-p = 0.014 obtenido con R, el cual esta asociado con el **Deviance** y en este caso se puede decir que el modelo Weibull ajusta medianamente bien.

En realidad

$$D = 2 * (Loglik_{Modelo\ con\ covariables} - Loglik_{Modelo\ solo\ intercepto})$$

$$D = 2 * (-154.3 + 157.3)$$

$$D = 6$$

Ahora veremos el valor **scale**, que en nuestro caso es **0.823**, la regla para esto es que si esta entre 0.5 y 1 sugiere que el hazard es creciente a una tasa decreciente. Esto sugiere que la tasa de ocurrencia de la progresión del cáncer de ovario aumenta a medida que aumenta el tiempo, pero a una tasa cada vez más lenta.

El signo negativo de la estimacion en grupo indica que estar en el grupo 2 representa una disminucion en el log de la supervivencia y por tanto incrementa el log del hazard.

De acuerdo a los valores de W. Para grupo:

$$(\frac{-0.941}{0.407})^2 = 5.3455$$

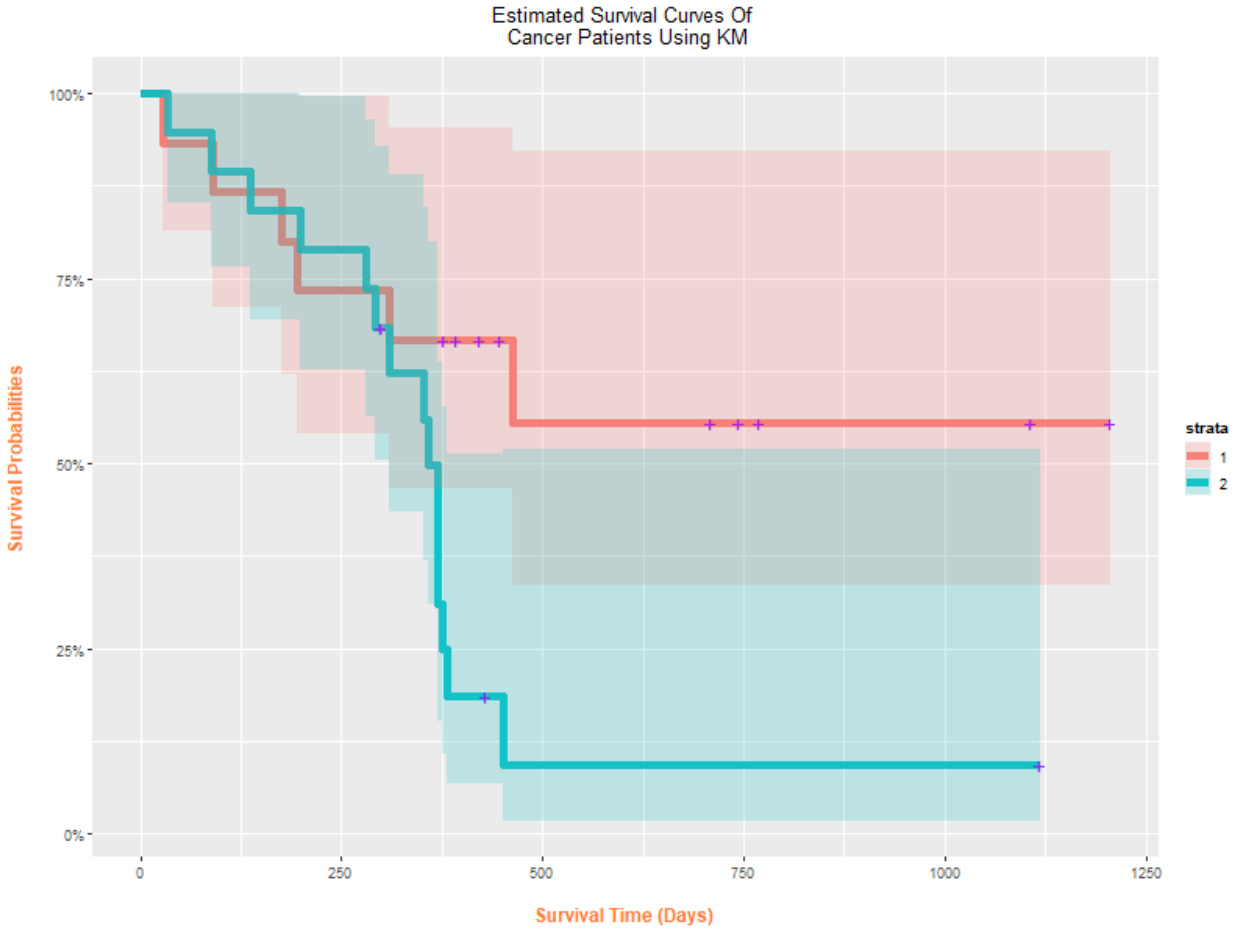

En la grafica anterior se observa la funcion de supervivencia, que proporciona la probabilidad de que una persona sobreviva mas alla de cierto tiempo, por ejemplo en el dia 0 (al inicio del estudio), la probabilidad de supervivencia es del 100% (ya que aun nadie a experimentado el evento de interes) para todos las personas que estan bajo observacion y a riesgo, y a medida de que transcurre el tiempo (dias) esta probabilidad disminuye para cada grupo. Para este caso podemos visualizar que el comportamiento en ambos en ambos grupos es relativamente similar hasta el dia 199 donde ya se empieza a ver una diferencia mas significativa entre ambos grupos. Despues de este punto el grupo 2 pareciese como que va a ser mejor que el grupo 1, hasta que en el dia 280 vemos que se desploma rapidamente la probabilidad de supervivencia pasando de un **73.3%** en el dia 280 a un **18.7%** en el dia 382, en solo 102 dias las probabilidades de supervivencia en el grupo 2 cambiaron radicalmente, lo que nos lleva a preguntarnos, ¿que paso en ese tiempo?, ¿por que en el grupo 2 se redujo tan rapido la probabilidad de supervivencia?. Por otro lado en el grupo 2 a partir del dia 199 se reduce su probabilidad de supervivencia (hasta que se de el evento de interes) mas lentamente y manteniendose **55.56%** a partir del dia 462 lo cual es una buena experiencia de supervivencia.

b) Con estos datos sin usar Log Rank test prueba la hipotesis $H0 : S1(t) = S2(t)$ para todo t. Use un = 0.05 ¿Qué se puede concluir? Del ajuste del modelo Weibull se obtiene un valor p = 0.021, como $0.021 < 0.05$ se rechaza la hipótesis nula y se concluye que $S1(t) \neq S2(t)$ ya que hay evidencia suficiente para afirmar que el grupo 2 tiene una diferencia significativa en el log de la supervivencia en comparación con el grupo 1.

Ahora que ya tenemos evidencia estadistica suficiente para decir que ambas curvas de supervivencia son distintas ahora procederemos a evaluar en cual es mejor la experiencia de supervivencia de forma cuantitativa, para esto calcularemos el hazard promedio para ambos grupos.

Grupo 1

$$\bar{T} = \frac{1}{n}\sum_{i=1}^{n} t_i$$

$$\bar{T} = \frac{1}{15}\sum_{i=1}^{15} t_i = 495.4$$

$$\bar{h} = \frac{fallas}{n\bar{T}}$$

$$\bar{h} = \frac{6}{15 * 495.4} = 0.0008074283$$

Grupo 2

$$\bar{T} = \frac{1}{n}\sum_{i=1}^{n} t_i$$

$$\bar{T} = \frac{1}{19}\sum_{i=1}^{19} t_i = 342.6316$$

$$\bar{h} = \frac{fallas}{n\bar{T}}$$

$$\bar{h} = \frac{15}{19 * 342.6316} = 0.002304147$$

A mayor hazard menor probabilidad de supervivencia, en este caso se observa que $\bar{h_1} < \bar{h_2}$ y $\bar{T_1} > \bar{T_2}$, por lo que de manera muy general se puede argumentar que la experiencaia de supervivencia en el grupo 2 es menor a la que se vive en el grupo 1, lo cual confirma lo que podemos ver en la grafica antes vista.

Ejercicio 3

Sean Y_1 y Y_2 dos variables aleatorias las cuales corresponde a:

Y_1 **: Tiempo de supervivencia con enfermedad del corazón.**

Y_2 **: Tiempo de supervivencia con enfermedad del riñon.**

Vamos a suponer que $Y_1 \sim f_1(t_1|\lambda_1)$ y $Y_2 \sim f_2(t_2|\lambda_2)$ con Y_1 y Y_2 independientes con $T = min(Y_1, Y_2)$

De la forma $Y_1 > 0$ y $Y_2 > 0 \Rightarrow T > 0$

$$\begin{aligned} P(T \leq t) &= 1 - P(T > t) \\ &= 1 - P(t_{min=(y_i)} > t) \\ &= 1 - P(Y_1 > t \wedge Y_2 > t) \\ &= 1 - [P(Y_1 > t) * P(Y_2 > t)] \\ &= 1 - [e^{-t\lambda_1} * e^{-t\lambda_2}] \\ &= 1 - e^{-t(\lambda_1+\lambda_2)} = 1 - S_T(t) \end{aligned}$$

Al derivar obtenemos la fdp:

$$\begin{aligned} \frac{d[1 - S_T(t)]}{dt} &= (\lambda_1 + \lambda_2)e^{-t(\lambda_1+\lambda_2)} \\ f_T(t) &= (\lambda_1 + \lambda_2)e^{-t(\lambda_1+\lambda_2)} \end{aligned}$$

Por lo tanto $T \sim exp(\lambda_1 + \lambda_2)$

Con respecto a su Hazard tenemos que:

$$h_T(t) = \frac{f_T(t)}{S_T(t)} = \frac{(\lambda_1 + \lambda_2)e^{-t(\lambda_1+\lambda_2)}}{e^{-t(\lambda_1+\lambda_2)}} = \lambda_1 + \lambda_2$$

¿Cuál de las dos enfermedades causarán primero la muerte a un paciente?

Dado el vínculo íntimo entre el riesgo y la función de superveniencia, se verifica que:

$$S_T(t_i) < S_T(t_j) \Rightarrow h_T(t_i) > h_T(t_j)$$
$$S_T(t_i) > S_T(t_j) \Rightarrow h_T(t_i) < h_T(t_j)$$

Para,

$$i = 1, j = 2$$

De acuerdo con la relación estrecha entre el riesgo y la función de superveniencia, se puede concluir que la enfermedad que causará la muerte inicial de un paciente es aquella con una menor probabilidad de supervivencia. En otras palabras, la enfermedad que presenta el mayor riesgo se convertirá en el desencadenante del desenlace fatal. Esta conexión intrínseca entre el peligro inherente y la capacidad de sobrevida nos permite comprender que, en la batalla contra las enfermedades, es crucial identificar y abordar con prontitud aquellas que llevan consigo un mayor grado de riesgo para garantizar una atención médica adecuada y, en última instancia, la vida del paciente.

¿Qué se puede decir del hazard de T?

Tal como cabía esperar, debido a la propiedad de pérdida de memoria inherente a la distribución exponencial, se puede apreciar un Hazard constante. $(\lambda_1 + \lambda_2)$ Según esta perspectiva, se adquiere un nivel constante de vulnerabilidad a lo largo del tiempo, ya que el riesgo de fracasar en cualquier momento es igual. Este riesgo está determinado completamente por la enfermedad que tenga la menor tasa de supervivencia, lo que a su vez aumenta el peligro potencial en λ_t veces con $t{=}min(Y_1{,}Y_2)$.

4. (TEÓRICO) Prueba lo siguiente: si $\log T \sim$ normal(μ, σ), entonces $T \sim$ lognormal(μ, σ)

Para demostrar que si $\log T$ sigue una distribución normal con parámetros de media y desviación estándar μ y σ respectivamente, entonces T sigue una distribución lognormal con parámetros de ubicación y escala también μ y σ, podemos utilizar propiedades básicas de las funciones exponencial y logaritmo.

La distribución lognormal se define como la distribución de una variable aleatoria $Y = e^X$, donde X sigue una distribución normal con parámetros μ y σ. En términos matemáticos, si $\log T$ sigue una distribución normal con parámetros μ y σ, entonces podemos expresar esto como:

$\log T \sim \text{normal}(\mu, \sigma)$

Esto significa que la variable aleatoria $\log T$ tiene una distribución normal con media μ y desviación estándar σ. Para demostrar que T sigue una distribución lognormal, necesitamos encontrar la función de densidad de probabilidad de T y mostrar que coincide con la forma de una distribución lognormal.

Primero, consideremos $Y = \log T$, donde Y es la variable aleatoria logaritmo natural de T. Si $\log T$ sigue una distribución normal con parámetros μ y σ, entonces podemos expresar esto como:

$Y \sim \text{normal}(\mu, \sigma)$

Ahora, utilizando la definición de la distribución lognormal, podemos expresar T en términos de Y como $T = e^Y$. También necesitamos encontrar la derivada de la función inversa $Y = \log T$ con respecto a T. La derivada es $\frac{dY}{dT} = \frac{1}{T}$.

Aplicamos el cambio de variable en la función de densidad de probabilidad de Y:

$f_Y(y) = f_T(t) \left| \frac{dt}{dy} \right| = f_T(e^y) \left| \frac{1}{e^y} \right| = \frac{1}{e^y \sigma \sqrt{2\pi}} \exp\left(-\frac{(\log(e^y) - \mu)^2}{2\sigma^2} \right) \cdot \frac{1}{e^y} = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(y-\mu)^2}{2\sigma^2} \right)$

Observamos que esta es la función de densidad de probabilidad de una distribución lognormal con parámetros de ubicación y escala μ y σ. Por lo tanto, hemos demostrado que si $\log T \sim \text{normal}(\mu, \sigma)$, entonces $T \sim \text{lognormal}(\mu, \sigma)$.

5. (TEÓRICO) Pruebe lo siguiente: si $T \sim$ lognormal(μ, σ), entonces $\log T \sim$ normal(μ, σ).

Para demostrar que si T sigue una distribución lognormal con parámetros de ubicación y escala μ y σ respectivamente, entonces $\log T$ sigue una distribución normal con parámetros de media y desviación estándar también μ y σ, podemos utilizar propiedades básicas de las funciones logaritmo y exponencial.

La distribución lognormal se define como la distribución de una variable aleatoria $Y = e^X$, donde X sigue una distribución normal con parámetros μ y σ. En términos matemáticos, si T sigue una distribución lognormal con parámetros μ y σ, entonces su función de densidad de probabilidad (pdf) está dada por:

$$f_T(t) = \frac{1}{t\sigma\sqrt{2\pi}} \exp\left(-\frac{(\log(t) - \mu)^2}{2\sigma^2} \right)$$

Para demostrar que $\log T$ sigue una distribución normal con parámetros μ y σ, necesitamos encontrar la función de densidad de probabilidad de $\log T$ y mostrar que coincide con la forma de una distribución normal.

Primero, consideremos $Y = \log T$, donde Y es la variable aleatoria transformada por el logaritmo natural. Para encontrar la función de densidad de probabilidad de Y, necesitamos utilizar el método del cambio de variable. Es decir, necesitamos encontrar la función de densidad de probabilidad de Y en términos de la variable t.

Tomemos el logaritmo natural en ambos lados de la ecuación $T = e^Y$:

$$\log T = \log(e^Y)$$
$$Y = \log T$$

Dado que $Y = \log T$, podemos expresar la variable t en términos de Y como $t = e^Y$. También necesitamos encontrar la derivada de la función inversa $t = e^Y$ con respecto a Y. La derivada es $\frac{dt}{dY} = e^Y$.

Aplicamos el cambio de variable en la función de densidad de probabilidad original de T:

$$\begin{aligned} f_T(t) &= \frac{1}{t\sigma\sqrt{2\pi}} \exp\left(-\frac{(\log(t)-\mu)^2}{2\sigma^2}\right) \\ &= \frac{1}{e^Y\sigma\sqrt{2\pi}} \exp\left(-\frac{(\log(e^Y)-\mu)^2}{2\sigma^2}\right) \\ &= \frac{1}{e^Y\sigma\sqrt{2\pi}} \exp\left(-\frac{(Y-\mu)^2}{2\sigma^2}\right) \end{aligned}$$

Ahora, vamos a encontrar la función de densidad de probabilidad de Y. Utilizamos la fórmula del cambio de variable:

$$f_Y(y) = f_T(t)\left|\frac{dt}{dY}\right|$$

$$f_Y(y) = f_T(t)\left|\frac{dt}{dY}\right|$$

$$= \frac{1}{e^Y\sigma\sqrt{2\pi}} \exp\left(-\frac{(Y-\mu)^2}{2\sigma^2}\right)$$

Finalmente, simplificamos la expresión:

$$f_Y(y) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(Y-\mu)^2}{2\sigma^2}\right)$$

Observamos que esta es la función de densidad de probabilidad de una distribución normal con parámetros de media μ y desviación estándar σ. Por lo tanto, hemos demostrado que si $T \sim \text{lognormal}(\mu, \sigma)$, entonces $\log T \sim \text{normal}(\mu, \sigma)$.

Ejercicio 6

Para las demostraciones de los ejercicios seis y siete, debemos tener en cuenta lo siguiente:

Supongamos que tenemos dos variables aleatorias continuas X **e** Y **tales que** $X \sim Logis(\mu, \sigma)$ **y** $Y \sim Loglogis(\mu, \sigma)$. **De la forma que:**

$$f_X(x) = \frac{e^{\frac{-(x-\mu)}{\sigma}}}{\sigma\left(1+e^{\frac{-(x-\mu)}{\sigma}}\right)^2} = \frac{1}{\sigma}\frac{1}{\left(e^{\frac{(x-\mu)}{2\sigma}}+e^{\frac{-(x-\mu)}{2\sigma}}\right)^2},\ x \in \mathbb{R}$$

$$f_Y(y) = \frac{y^{\frac{1}{\sigma}-1}}{\sigma}\frac{1}{(e^{\mu/2\sigma}+y^{1/\sigma}e^{-\mu/2\sigma})^2},\ y > 0$$

Ejercicio seis.

Sea T una variable aleatoria de la forma que $T \sim loglogis(\mu, \sigma)$. Consideremos que $Y = log(T) \sim logis(\mu, \sigma)$.

Se cumple que:

$$\begin{aligned}
f_Y(y) &= f_T(e^y)\left|\frac{d}{dy}e^y\right| \\
&= \frac{e^{\frac{y}{\sigma}-y}}{\sigma}\frac{1}{\left(e^{\frac{\mu}{2\sigma}}+e^{\frac{y}{\sigma}}e^{-\frac{\mu}{2\sigma}}\right)^2}|e^y| \\
&= \frac{1}{\sigma}\frac{1}{[e^{-\frac{y}{2\sigma}}\left(e^{\frac{\mu}{2\sigma}}+e^{\frac{y}{\sigma}}e^{-\frac{\mu}{2\sigma}}\right)]^2} \\
&= \frac{1}{\sigma}\frac{1}{\left(e^{\frac{\mu-y}{2\sigma}}+e^{\frac{y-\mu}{2\sigma}}\right)^2} \\
&= \frac{1}{\sigma}\frac{1}{\left(e^{\frac{y-\mu}{2\sigma}}+e^{-\frac{y-\mu}{2\sigma}}\right)^2}
\end{aligned}$$

$con\ y \in \mathbb{R}$

En consecuencia $Y \sim logis(\mu, \sigma)$

Entonces, si T es una variable aleatoria continua y cumple con la condición de que $T \sim loglogis(\mu, \sigma) \rightarrow log\,T \sim logis(\mu, \sigma)$.■

Ejercicio 7.

Sea T una variable aleatoria de la forma que $Y = log\,T \sim logis(\mu, \sigma)$. Supongamos que $T \sim loglogis(\mu, \sigma)$.

Tenemos que,

$$
\begin{aligned}
f_T(t) &= f_Y(log(t)) \left| \frac{d}{dt} log(t) \right| \\
&= \frac{1}{\sigma} \frac{1}{\left(e^{(log(t)-\mu)/2\sigma} + e^{-(log(t)-\mu)/2\sigma}\right)^2} \left| \frac{1}{t} \right| \\
&= \frac{1}{\sigma} \frac{1}{\left(t^{1/2\sigma} e^{-\mu/2\sigma} + t^{-1/2\sigma} e^{\mu/2\sigma}\right)^2} \frac{1}{t} \\
&= \frac{t^{-1}}{\sigma} \frac{1}{\left[t^{-1/2\sigma}\left(t^{1/\sigma} e^{-\mu/2\sigma} + e^{\mu/2\sigma}\right)\right]^2} \\
&= \frac{t^{\frac{1}{\sigma}-1}}{\sigma} \frac{1}{(e^{\mu/2\sigma} + t^{1/\sigma} e^{-\mu/2\sigma})^2}
\end{aligned}
$$

$Con\ t > 0$

Por lo tanto obtenemos, $t \sim loglogis(\mu, \sigma)$.

Por consiguiente, si T una variable aleatoria continua por lo que $log\,T \sim logis(\mu, \sigma)$ $\rightarrow T \sim loglogis(\mu, \sigma)$.■