Trabajo 2

Katerin Gómez C

Juan Diego Espinosa H

Daniel Felipe Puentes R.

Juan Pablo Chalarca.

SERIES DE TIEMPO UNIVARIADAS

2024-1

Cesar Augusto Gomez Velez

Universidad Nacional de Colombia

Sede Medellín

Facultad de Ciencias

Medellín, Agosto 2024

Punto 1

Para la elección de la base de datos del trabajo, escogimos el ultimo digito del número de cedula de cada uno de lo cuatro integrantes del grupo (9, 0, 2, 6) donde la suma de este da 17, y su residuo cuando se divide por 4 es de 1. Por lo que nuestra base de datos será 'Serie01_We_W6.csv.'

Antes de realizar la resolucion de los puntos, iniciaremos con un analisis descriptivo para asi tener una mejor compresion inicial de los datos

```
library(stats)
library(ggplot2)
```

```
## Warning: package 'ggplot2' was built under R version 4.3.3
```

```
datos <- read.csv("Serie01_We_02_W6.csv", header = T, sep = ";", dec = ",")

serie <- ts(datos$x, start = 1871, end = 1985)
```

```
plot(serie, type="l", col="blue", main="Serie de Tiempo", xlab="Tiempo", ylab="Valor")
```

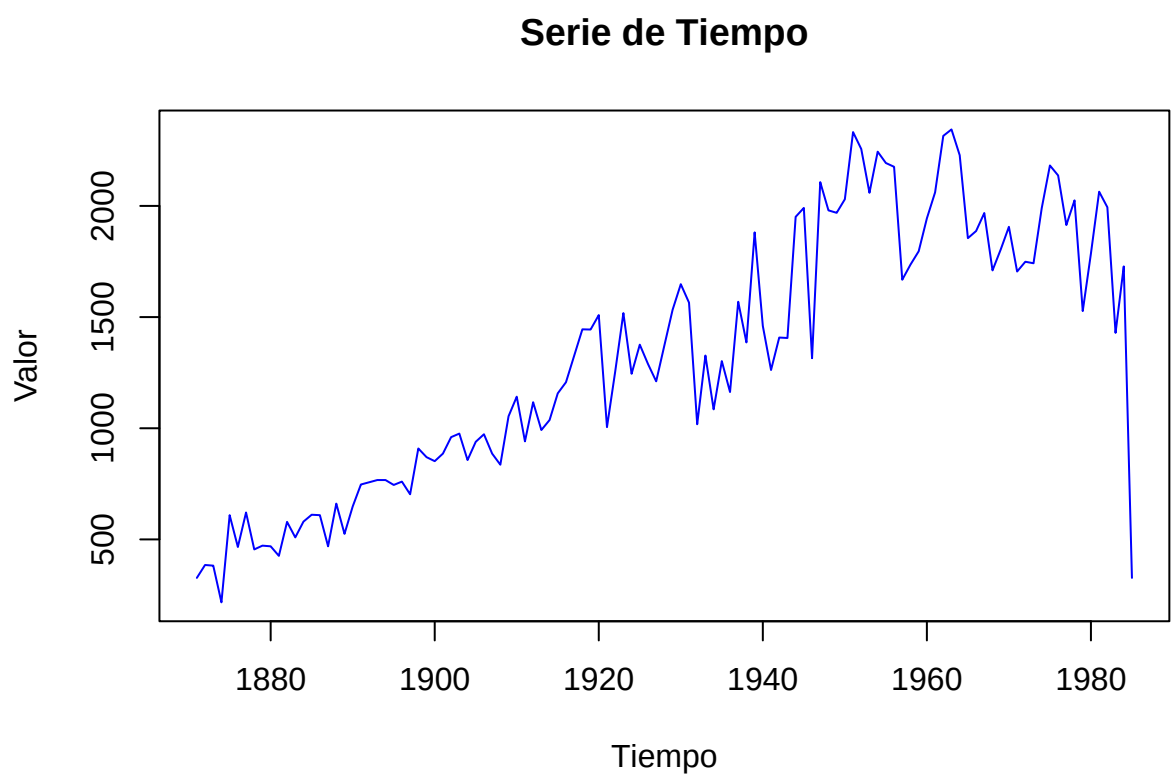

Inicialmente, se observa una tendencia general ascendente desde 1871 hasta aproximadamente 1940, a partir de ahi, la serie presenta una mayor volatilidad.

Despues de aproximadamente 1960-1970, la serie presenta un descenso abrupto, especialmente hacia el final. Este comportamiento en la serie, puede llegar a ser un pinto de interés ya que puede indicar un cambio estructural en la serie o un evento negativo

```
plot.ts(diff(serie), col="blue", main="Serie de Tiempo", xlab="Tiempo", ylab="Valor")
```

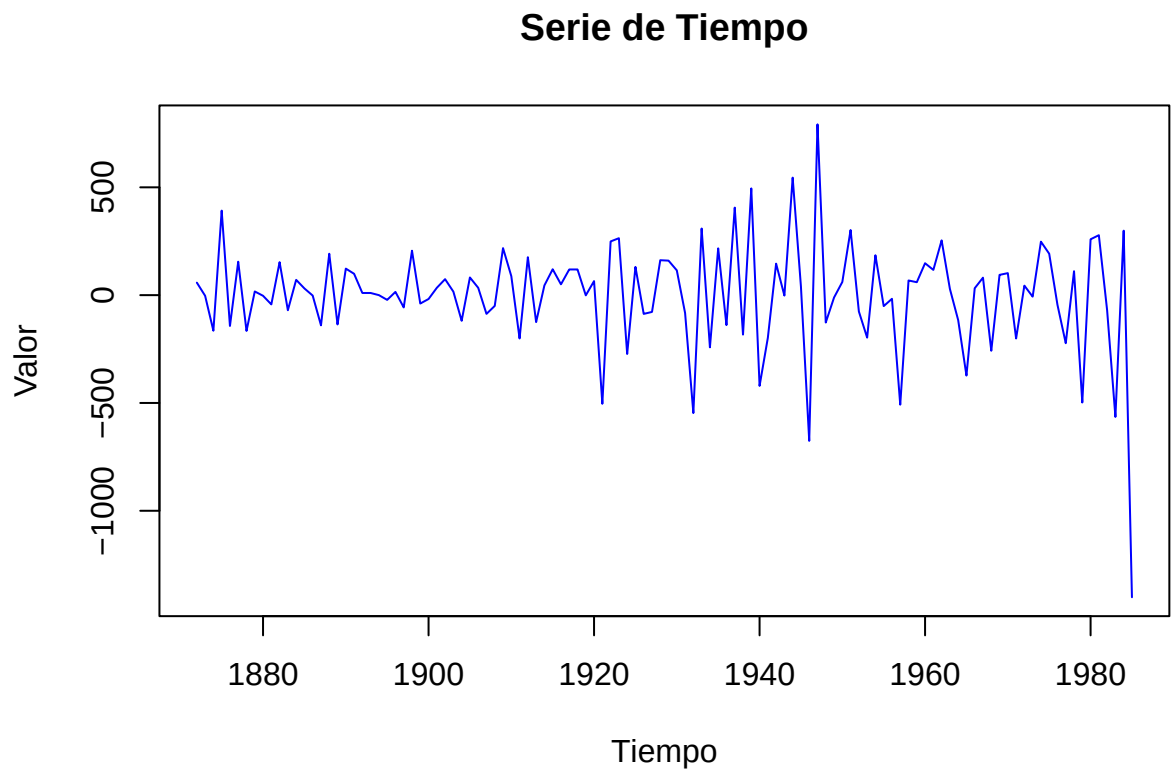

Por otro lado, esta grafica muestra que la variabilidad en ciertos puntos (entre 1880 y 1910 aproximadamente) es constante, pero no es suficiente para considerar una varianza constante. Y al igual que en la grafica anterior se observan algunos outliers que podrían requerir un análisis adicional.

Literal a

En este análisis, es de utilidad verificar si es necesario realizar una transformación Box-Cox a los datos. Este enfoque es valioso porque busca encontrar la transformación de potencia óptima que hace que los datos se asemejen a una distribución normal. Su fórmula está dada de la siguiente manera:

$$Z^{\lambda} = \begin{cases} \frac{(Z^{\lambda}-1)}{\lambda} & \text{si } \lambda \neq 0 \\ \ln(Z) & \text{si } \lambda = 0 \end{cases}$$

En esta fórmula, Z representa la variable respuesta original, y λ es el valor que optimiza la normalidad de los datos. Si λ es igual a 1, la transformación es lineal; de lo contrario, se aplica una transformación de potencia.

```
library(MASS)
boxcox_result <- boxcox(serie ~ as.numeric(time(serie)))
```

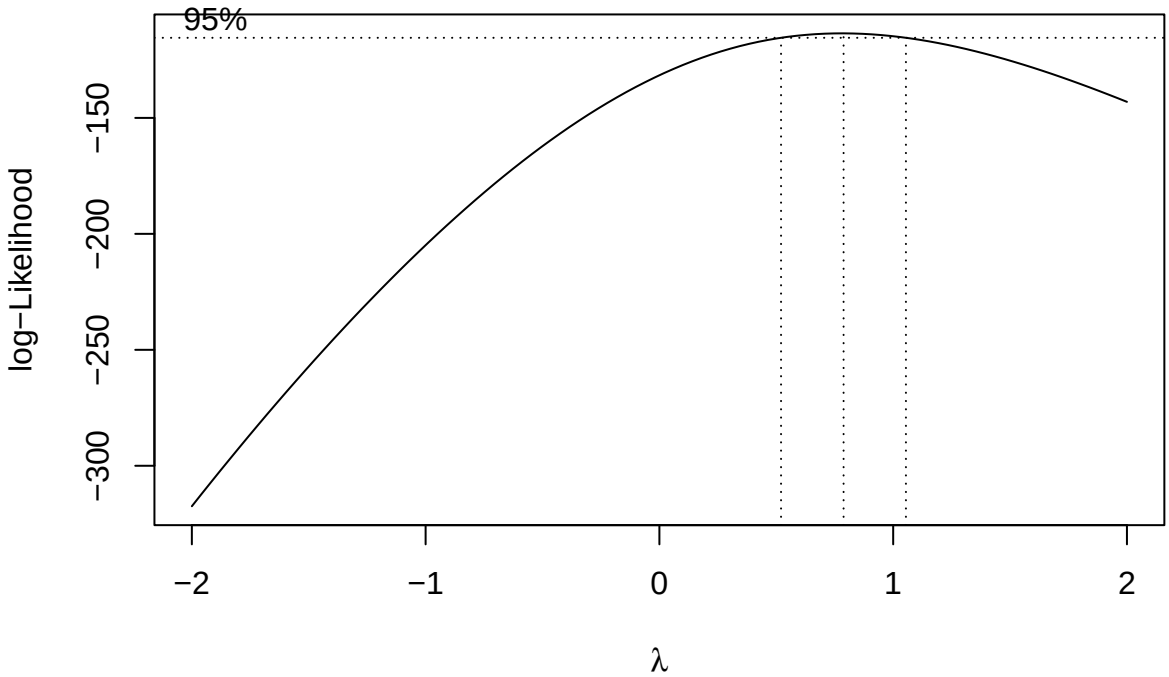


```
lambda_optimo <- boxcox_result$x[which.max(boxcox_result$y)]
lambda_optimo
```

```
## [1] 0.7878788
```

Tras aplicar la transformación Box-Cox a nuestra serie temporal, obtuvimos un valor de $\lambda = 0.7878788$, este valor está relativamente cerca de 1, pero no es exactamente 1. Lo que nos sugiere que una transformación (aunque leve) podría llegar a ser beneficiosa para nuestros datos. Por tanto la fórmula de Box-Cox se aplica de la siguiente manera:

$$Z^{0.7878788} = \frac{(Z^{0.7878788} - 1)}{0.7878788}$$

Aplicando esto en R:

```
library(forecast)
serie_transformada <- BoxCox(serie, lambda = 0.7878788)
plot(serie_transformada, type="l", col="blue", main="Serie Transformada (Box-Cox)",
     xlab="Tiempo", ylab="Valor Transformado")
```

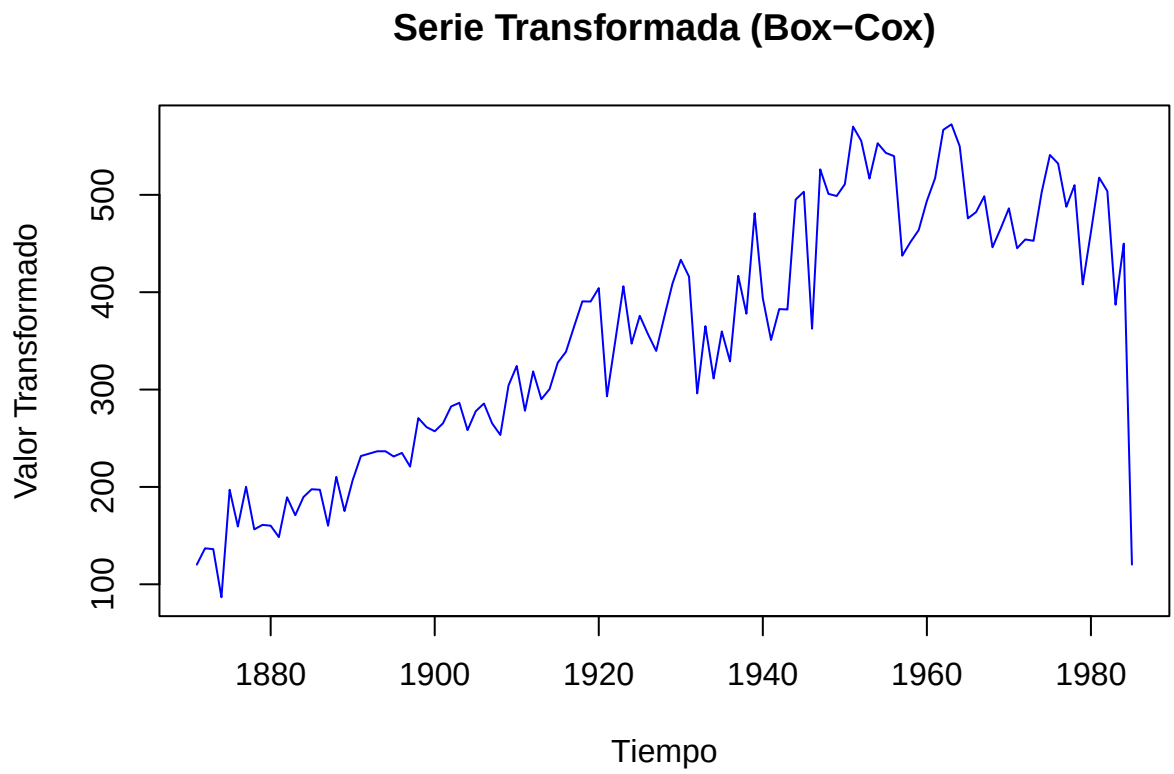


```r
plot.ts(diff(serie_transformada), col="blue", main="Serie Transformada (Box-Cox)",
        xlab="Tiempo", ylab="Valor Transformado")
```

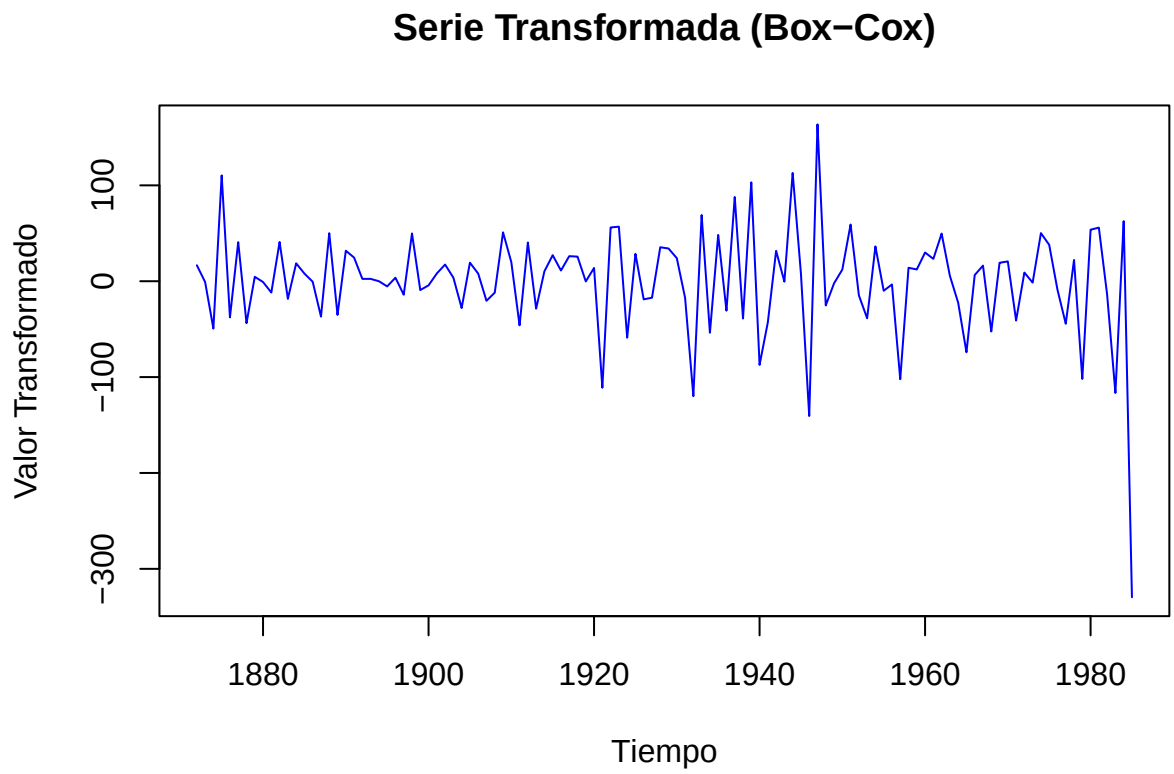

En estas graficas, no se aprecia ninguna variación significativa en comparación a la graficas del analisis descriptivo hecho anteriormente. Esto puede llegar a deberse al descenso abrupto mencionado anteriormente, a pesar de esto, se seguirá trabajando con la serie transformada

Literal b

Para realizar la prueba de raíces unitarias se opta por usar la prueba de Dickey-Fuller, en la que el juego de hipótesis está dada por:

$$H_0 : \phi = 1 \quad \text{vs} \quad \phi < 1$$

En esta prueba, H_0 establece que la serie tiene una raíz unitaria, lo que quiere decir que la serie no es estacionaria. Por otro lado, rechazar H_0 indicaria que la serie es estacionaria

```
library(urca)

df_prueba <- ur.df(serie_transformada, type = "none", lags = 0)
summary(df_prueba)
```

```
##
## ###############################################
## # Augmented Dickey-Fuller Test Unit Root Test #
## ###############################################
##
## Test regression none
##
##
```

```
## Call:
## lm(formula = z.diff ~ z.lag.1 - 1)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -324.57  -16.22    8.51   32.00  167.72
##
## Coefficients:
##         Estimate Std. Error t value Pr(>|t|)
## z.lag.1 -0.01123    0.01406  -0.799    0.426
##
## Residual standard error: 57.01 on 113 degrees of freedom
## Multiple R-squared:  0.005617,   Adjusted R-squared:  -0.003183
## F-statistic: 0.6383 on 1 and 113 DF,  p-value: 0.426
##
##
## Value of test-statistic is: -0.7989
##
## Critical values for test statistics:
##       1pct  5pct 10pct
## tau1 -2.58 -1.95 -1.62
```

Inicialmente, se aplica la prueba de Dickey-Fuller a la serie transformada. El resultado de la prueba arrojó un valor del estadístico de prueba de -0.7989, el cual es mayor a los valores de τ y por ende H_0 no puede ser rechazada lo que quiere decir que existe una raíz unitaria y la serie no es estacionaria, algo que refuerza lo visto en las graficas anteriores

En vista a esto se procede nuevamente a hacer la prueba de Dickey-Fuller, pero esta vez se diferencia la serie:

```r
df_prueba_diff <- ur.df(diff(serie_transformada), type = "none", lags = 0)
summary(df_prueba_diff)
```

```
##
## ###############################################
## # Augmented Dickey-Fuller Test Unit Root Test #
## ###############################################
##
## Test regression none
##
##
## Call:
## lm(formula = z.diff ~ z.lag.1 - 1)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -300.440  -13.932    6.915   27.453  112.732
##
## Coefficients:
##         Estimate Std. Error t value Pr(>|t|)
## z.lag.1  -1.4653     0.1035  -14.16   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 52.83 on 112 degrees of freedom
## Multiple R-squared:  0.6417, Adjusted R-squared:  0.6385
## F-statistic: 200.6 on 1 and 112 DF,  p-value: < 2.2e-16
```

```
##
##
## Value of test-statistic is: -14.1617
##
## Critical values for test statistics:
##       1pct  5pct 10pct
## tau1 -2.58 -1.95 -1.62
```

Nuevamente hecha la prueba el valor del estadistico de prueba es de -14.1617, este es menor a los valores τ, por ende se rechaza H_0. Esto sugiere que, tras la diferenciación, la serie ya no posee raíces unitarias, confirmando que se ha vuelto estacionaria.

Literal c

Para identificar un modelo ARIMA adecuado para la serie temporal, se detalla en los siguientes dos enfoques:

Análisis de Autocorrelogramas

Primero, se visualizan los autocorrelogramas de la serie transformada después de la diferenciación para identificar patrones estacionales y de autocorrelación:

```r
ggtsdisplay(diff(serie_transformada), col = "blue")
```

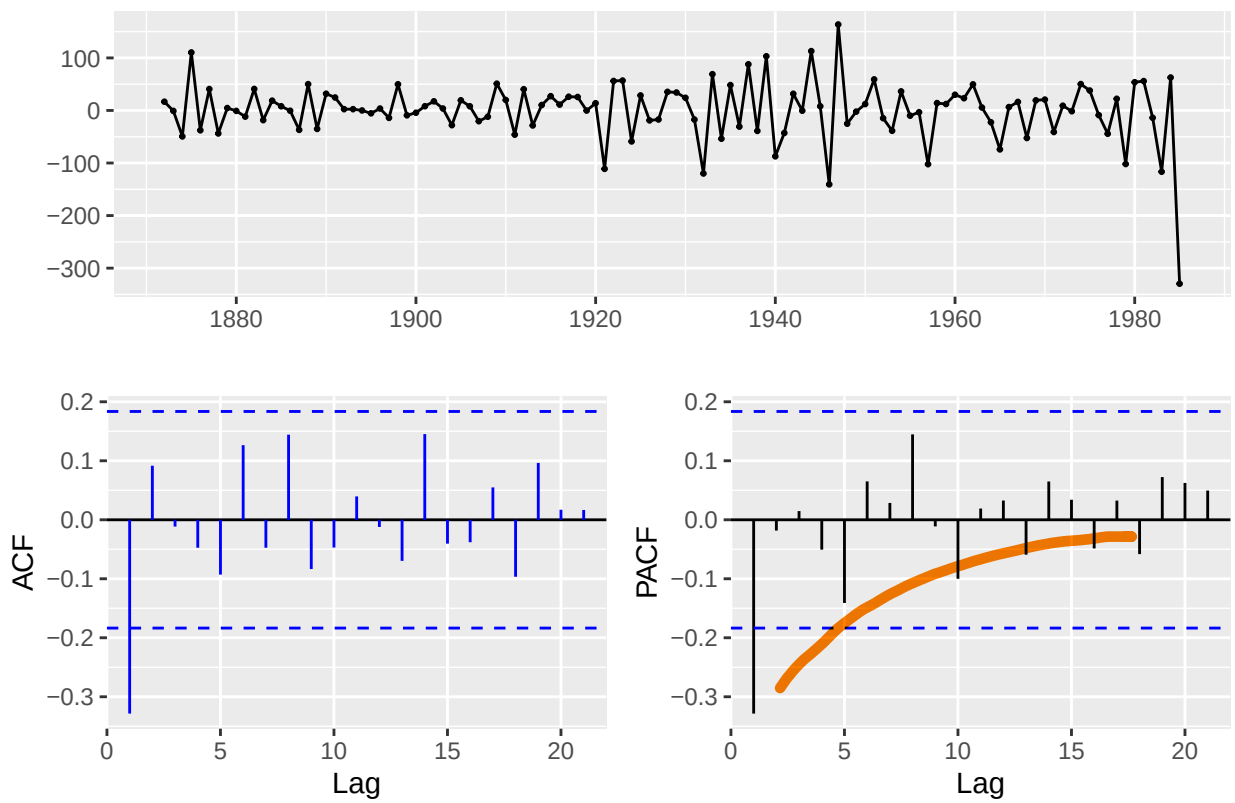

- Dado que se utilizó una serie diferenciada (d = 1), el orden de diferenciación es 1 en todos los posibles modelos propuestos
- En el ACF se muestra un pico significativo en el primer rezago

- El PACF presenta un pico significativo en el primer rezago, con picos menores en los rezagos 5 y 8. Tampoco hay un corte abrupto evidente

Basado en estos patrones, se pueden considerar modelos ARIMA(1, 1, 1), ARIMA(1, 1, 0), o ARIMA(0, 1, 1) como puntos de partida

Análisis mediante ESACF

Ahora, se emplea la función de autocorrelación muestral extendida para obtener una visión más detallada de las posibles estructuras de rezagos:

```
library(TSA)
eacf(diff(serie_transformada))
```

```
## AR/MA
##   0 1 2 3 4 5 6 7 8 9 10 11 12 13
## 0 x o o o o o o o o o o  o  o  o
## 1 o o o o o o o o o o o  o  o  o
## 2 x o o o o o o o o o o  o  o  o
## 3 x x o x o o o o o o o  o  o  o
## 4 x o o x o o o o o o o  o  o  o
## 5 o o x x o x o o o o o  o  o  o
## 6 x o x x x x x o o o o  o  o  o
## 7 o x x o o o o o o o o  o  o  o
```

De la tabla, se identifican la combinaciones adecuadas (marcadas como "o") para p y q, algunas de ellas son:

- ARIMA (0, 1, 1)
- ARIMA (1, 1, 1)
- ARIMA (1, 1, 2)
- ARIMA (2, 1, 1)
- ARIMA (2, 1, 2)
- ARIMA (3, 1, 1)

En cuestion de parsimonia, los modelos ARIMA (0, 1, 1) y ARIMA (1, 1, 1) son los mas sencillos.

Tomando en cuenta el análisis del ACF, PACF y ESACF, se identifica como mejor modelo el ARIMA (0, 1, 1) donde su formula esta dada por:

$$(1 - B)Z_t = (1 - \theta B)a_t$$

Literal d

```
auto.arima(serie^0.78,max.p=5,max.q=5)
```

```
## Series: serie^0.78
## ARIMA(0,1,1)
##
## Coefficients:
##           ma1
##       -0.4998
## s.e.   0.1084
##
## sigma^2 = 1505:  log likelihood = -578.45
## AIC=1160.9   AICc=1161.01   BIC=1166.37
```

Literal e

```r
mod1_CSS_ML=Arima(serie, c(0, 1, 1), include.drift=TRUE, lambda=0.78, method = c("CSS-ML"))
summary(mod1_CSS_ML)
```

```
## Series: serie
## ARIMA(0,1,1) with drift
## Box Cox transformation: lambda= 0.78
##
## Coefficients:
##           ma1   drift
##       -0.5167  1.3563
## s.e.   0.1140  2.2817
##
## sigma^2 = 2488:  log likelihood = -606.61
## AIC=1219.21   AICc=1219.43   BIC=1227.42
##
## Training set error measures:
##                     ME     RMSE      MAE       MPE     MAPE      MASE
## Training set 1.188705 236.9352 151.1451 -3.819327 15.19281 0.8820794
##                      ACF1
## Training set 0.004930544
```

Literal f

Para probar el diagnóstico del modelo que se identifico:

- Se analiza el circulo unitario: en este es posible observar que la raíz esta dentro del circulo lo cual nos indica que el proceso es ~~convergente en el largo plazo, es decir,~~ es estacionario.

```r
autoplot(mod1_CSS_ML)
```

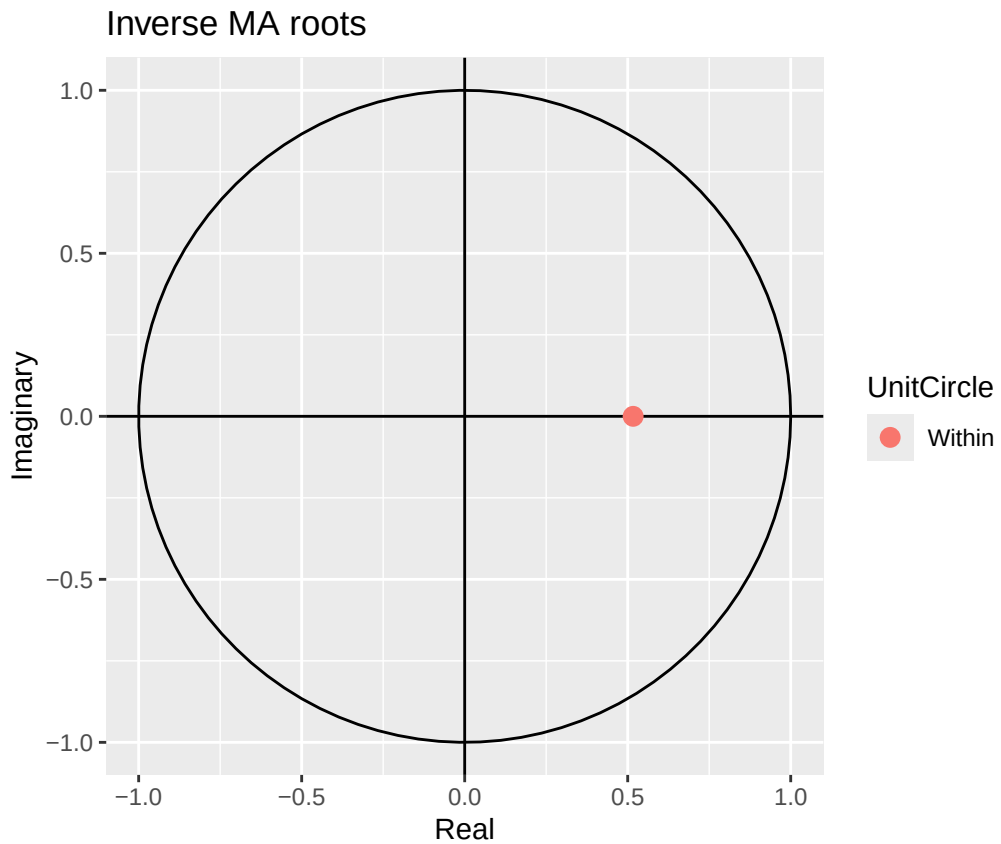

- Se observan los residuos:

```
tsdiag(mod1_CSS_ML)
```

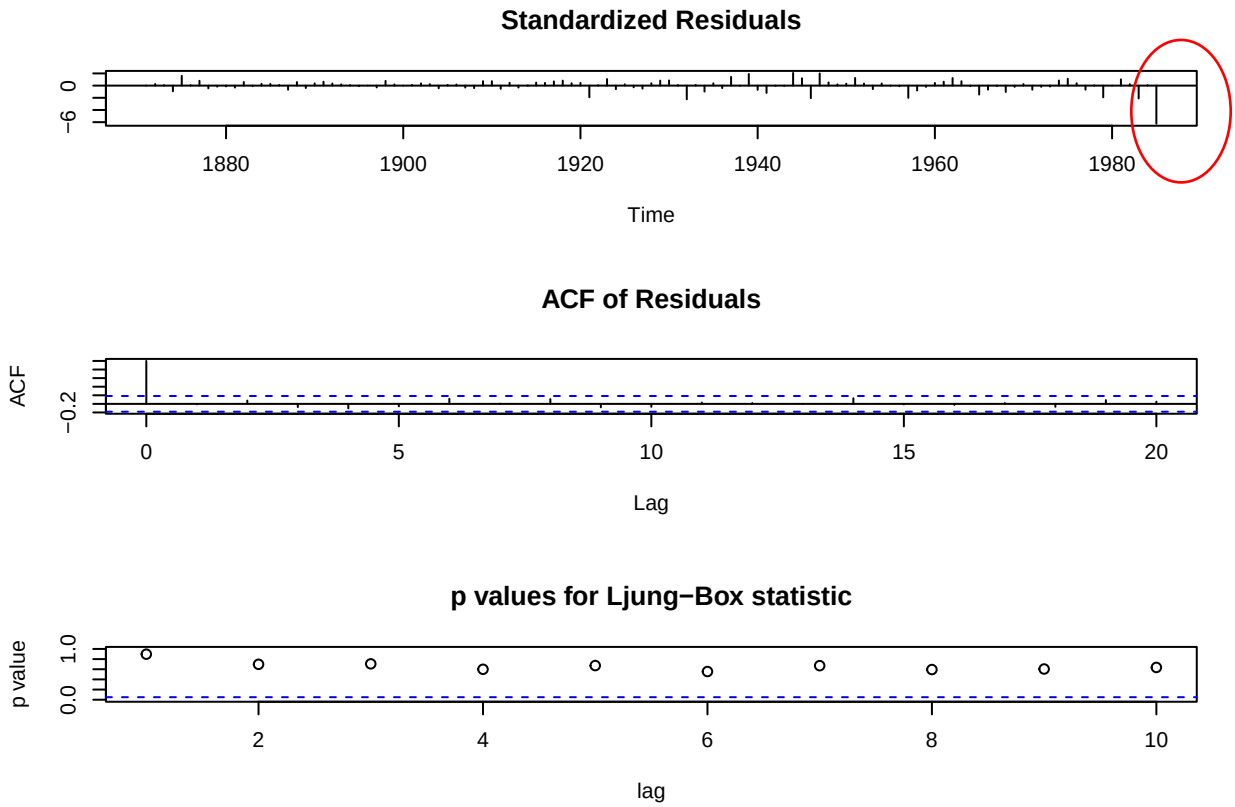

De ellos se observa que en la ACF los residuos estan dentro de las cintas de confianza, las bandas que ayudan a verificar la significancia y que los valores p estan por encima del nivel de significancia o.05, es decir se acepta la hipótesis nula donde se dice que los residuos del modelo no tienen autocorrelación significativa hasta el retardo (en este caso 10), es decir, son ruido blanco.

finalmente, se prueba normalidad de los residuos

```
res1_CSS_ML=residuals(mod1_CSS_ML)

res1_est=res1_CSS_ML/(mod1_CSS_ML$sigma2^0.5)
plot.ts(res1_est, main="Residuos del Modelo ARIMA(0,1,1)", ylab="Residuos", xlab="Tiempo")
abline(h=0, col="red")
```

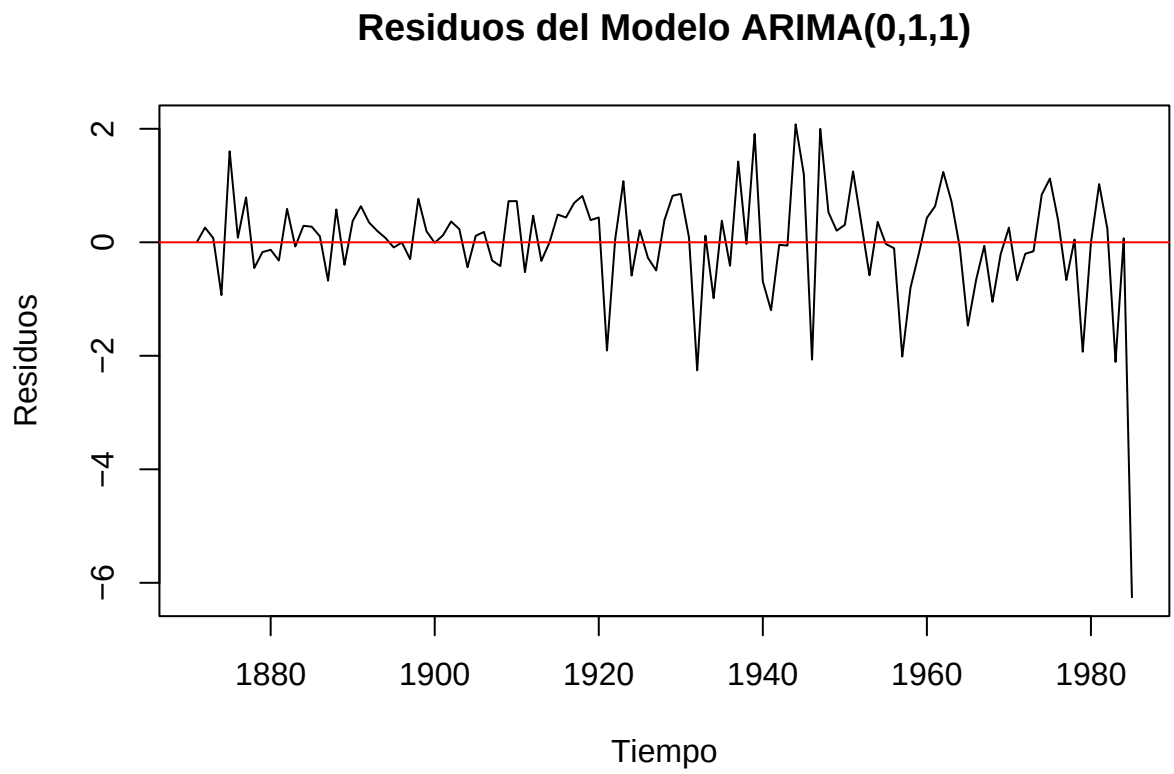


```
ind= (abs(res1_est)>3.0)
sum(ind)
```

```
## [1] 1
```

```
qqnorm(res1_est, xlab = "Cuantiles teoricos", ylab="Cuantiles muestrales", ylim = c(-3,3))
qqline(res1_est)
```

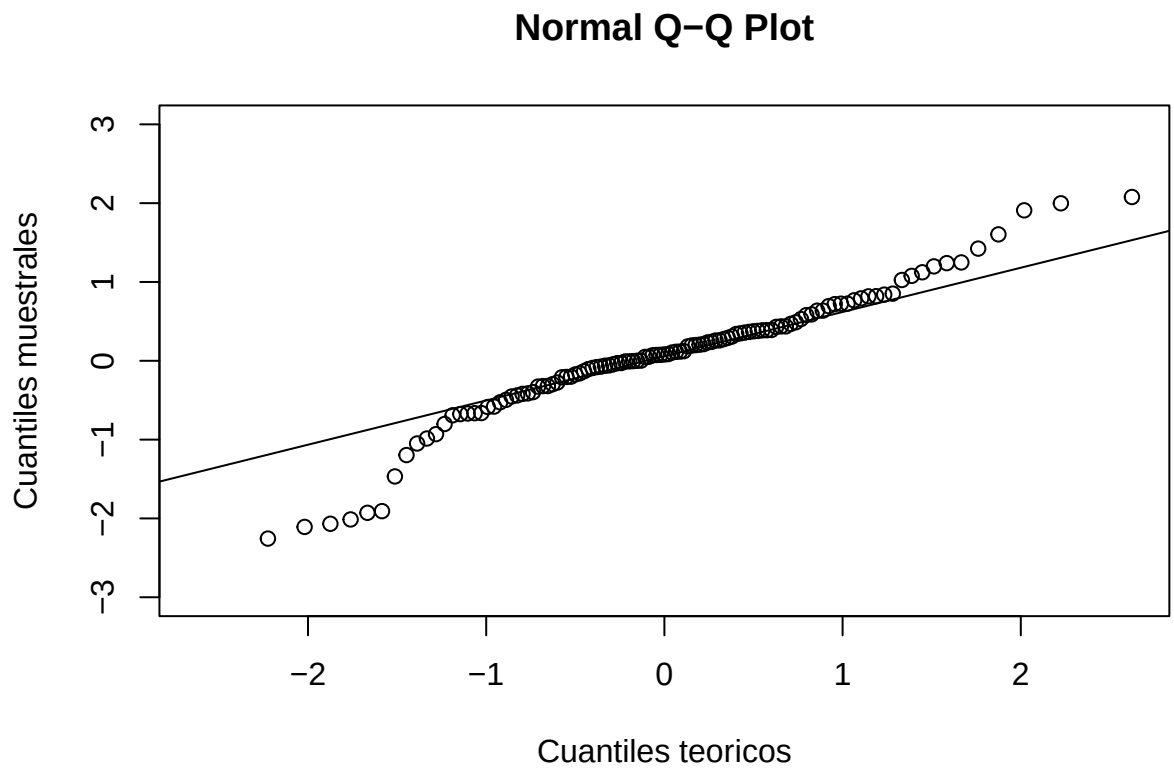


```r
shapiro.test(res1_est)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  res1_est
## W = 0.82685, p-value = 2.685e-10
```

Teniendo en cuenta lo anterior, se observa que los datos no son normales lo cual dificulta el proceso de hacer inferencia y se sugiere revisarlos para poder llegar a conclusiones claras.

Literal g

a.

Para este caso, observando la serie y el proceso ya realizado, se infiere que la serie contiene ambas, se observa una tendencia deterministica ya que tiene una forma consistente que sigue una forma específica a lo largo del tiempo, sin embargo es posible observar pequeños choques aleatorios en su camino, bien sea por errores aleatorios o por alguna perturbación en su historial.

b.

Observando la imagen (gráfica de la serie de tiempo original) y el proceso anterior es posible decir que se cuenta con una serie con diferencias estacionarias, esto dado que, no es estacionaria en su forma original pero se convierte en estacionaria después de aplicar diferencias suficientes, observación que se ratifica cuando se encuentran raices unitarias.

Punto 2

Literal a

```
library(readxl)
gasolin7<- read_excel("gasolin7.xlsx")
```

##Convertir a serie de tiempo con la función ts

```
gasol<-ts(gasolin7)
```

```
# Instalar y cargar las librerías necesarias
library(readxl)
library(forecast)

# Graficar la serie original y su diferencia
plot(gasol, ylab="Valor", xlab="Tiempo", main="Serie Original")
```

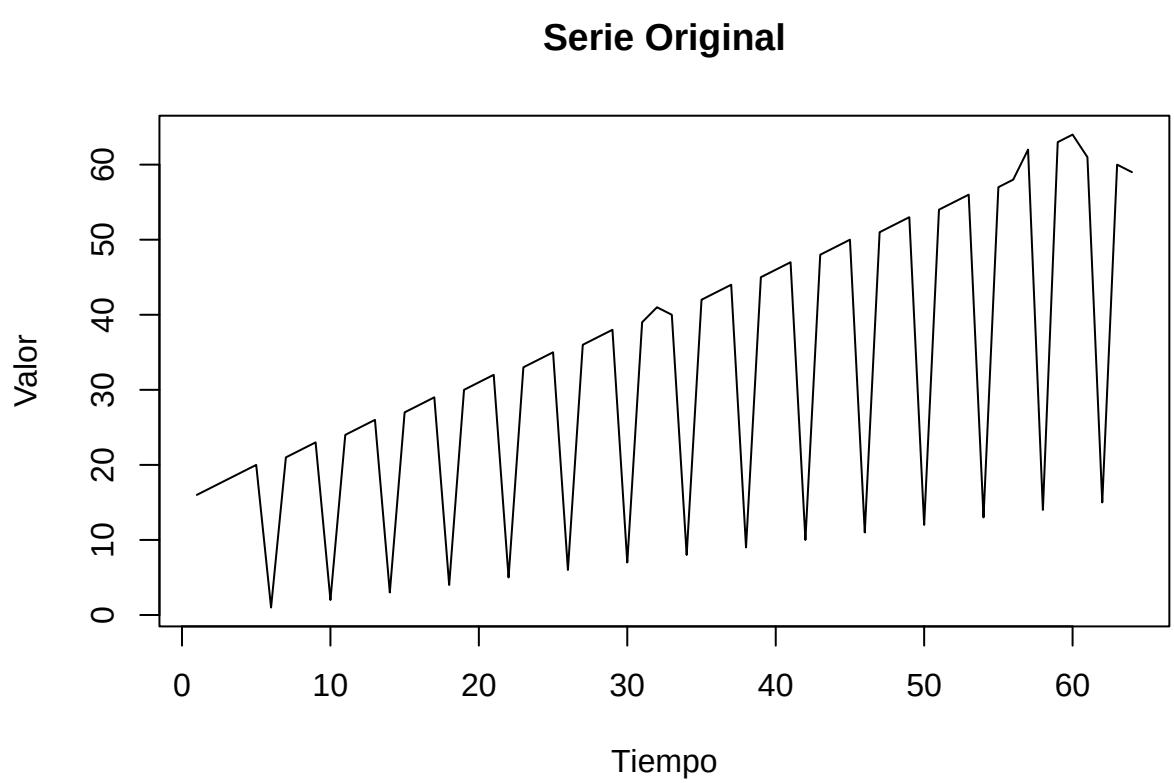


```
diferencia<-diff(gasol, main = "Serie Diferenciada")
plot(diferencia)
```

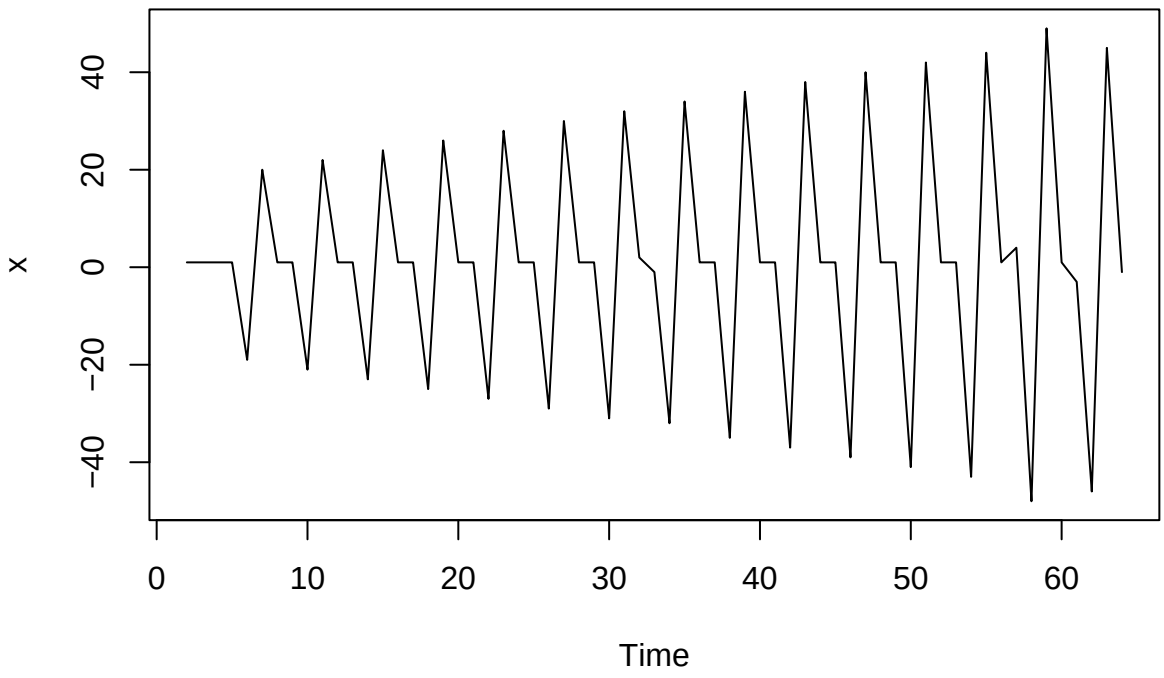

Se gráfica la serie y la diferencia donde se puede evidenciar que su varianza no es constante ya que está aumentando en el tiempo y en dirección de la tendencia. Esto indica que se debe transformar la serie donde se estabilice la varianza

Literal B

```
# Aplicar la transformación de Box-Cox
lambda_optimo <- BoxCox.lambda(gasol)
serie_transformada <- BoxCox(gasol, lambda = lambda_optimo)

# Graficar la serie transformada
plot(serie_transformada, type="l", col="blue", main="Serie Transformada (Box-Cox)",
     xlab="Tiempo", ylab="Valor Transformado")
```

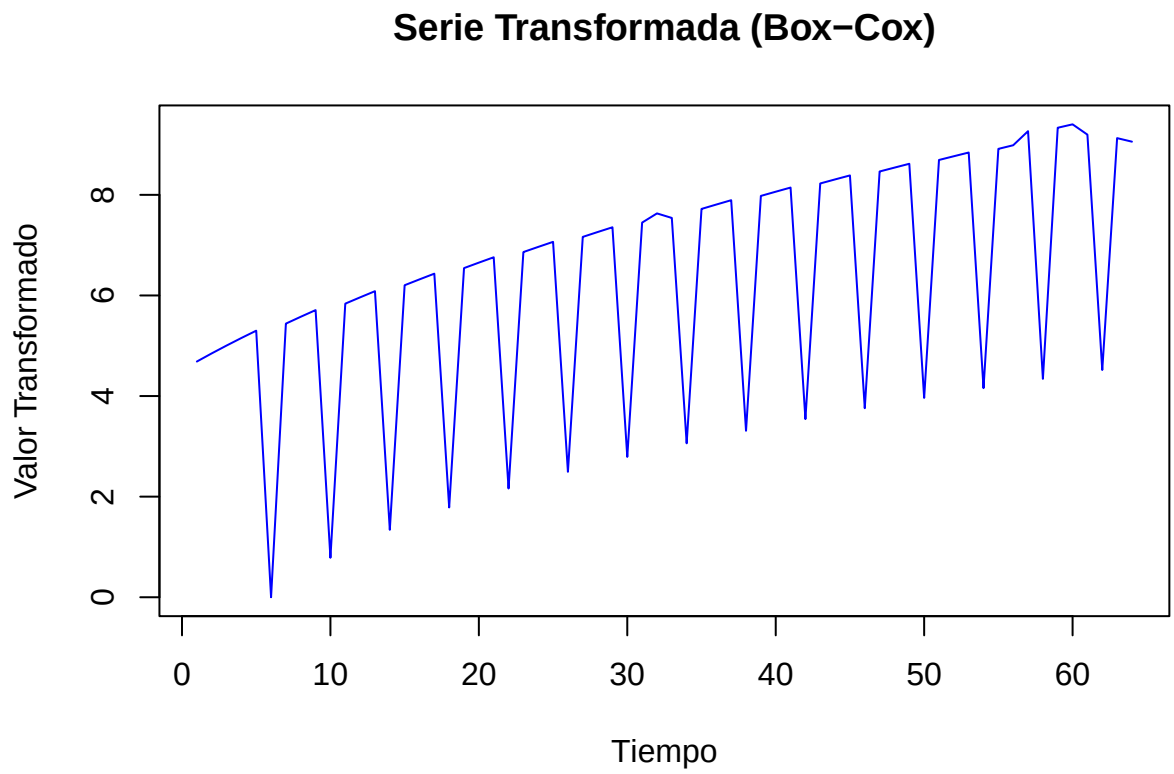


```r
# Diferenciar la serie transformada si es necesario
serie_transformada_diff <- diff(serie_transformada)
```

Una vez hecha la transformación con un $\lambda = 0.3504$, se evidencia una media 0 y una estabilización en su varianza, convirtiendose en varianza constante

Los modelos ARIMA deben ser estacionales, es decir que no deben tener raices unitarias. Para verificar esto se procede a hacer una prueba de Dickey-Fuller:

```r
ru_tz=ur.df(serie_transformada, type = "none", lags = 0)
summary(ru_tz)
```

```
##
## ###############################################
## # Augmented Dickey-Fuller Test Unit Root Test #
## ###############################################
##
## Test regression none
##
##
## Call:
## lm(formula = z.diff ~ z.lag.1 - 1)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -4.7174  0.6822  0.8832  1.1794  5.4696
##
## Coefficients:
```

```
##         Estimate Std. Error t value Pr(>|t|)
## z.lag.1 -0.10979    0.06075  -1.807   0.0756 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 3.226 on 62 degrees of freedom
## Multiple R-squared:  0.05004,    Adjusted R-squared:  0.03472
## F-statistic: 3.266 on 1 and 62 DF,  p-value: 0.07559
##
##
## Value of test-statistic is: -1.8072
##
## Critical values for test statistics:
##      1pct  5pct 10pct
## tau1 -2.6 -1.95 -1.61
```

El resultado de la prueba indica que el τ_{calulado} es mayor al τ_{critico}, por ende la serie tiene presencia de raices unitarias y es necesario diferenciar la serie.

Ahora, volviendo a hacer la prueba con la serie diferenciada:

```r
ru_tz_diff=ur.df(serie_transformada_diff, type = "none", lags = 0)
summary(ru_tz_diff)
```

```
##
## ###############################################
## # Augmented Dickey-Fuller Test Unit Root Test #
## ###############################################
##
## Test regression none
##
##
## Call:
## lm(formula = z.diff ~ z.lag.1 - 1)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -5.2269 -0.1280  0.2761  2.4237  2.8465
##
## Coefficients:
##         Estimate Std. Error t value Pr(>|t|)
## z.lag.1   -1.498      0.111   -13.5   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 2.893 on 61 degrees of freedom
## Multiple R-squared:  0.7491, Adjusted R-squared:  0.745
## F-statistic: 182.1 on 1 and 61 DF,  p-value: < 2.2e-16
##
##
## Value of test-statistic is: -13.496
##
## Critical values for test statistics:
##      1pct  5pct 10pct
## tau1 -2.6 -1.95 -1.61
```

Esta vez el τ_{calulado} es menor al τ_{critico}, indicando que la serie no tiene raices unitarias y por tanto es estacionaria

```
ggtsdisplay(serie_transformada_diff)
```

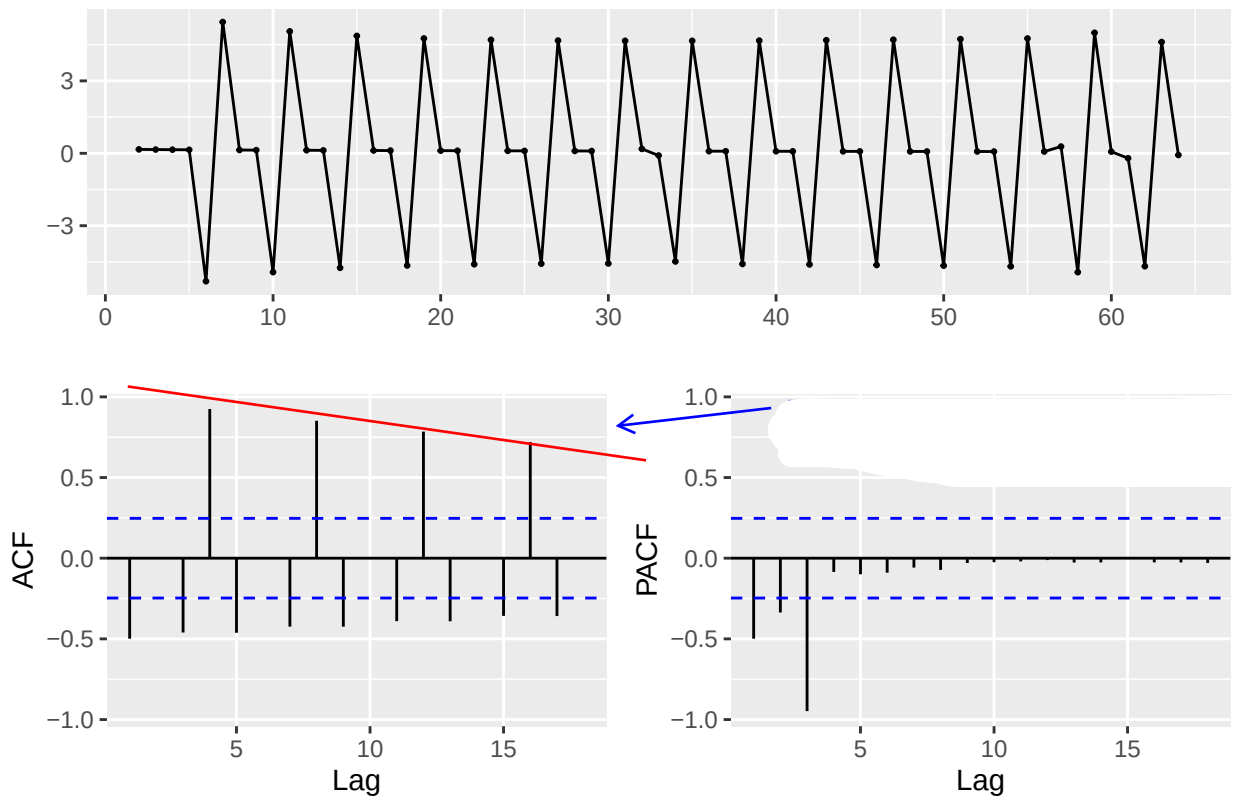

Haciendo la grafica del ACF y del PACF se nota un decaimiento leve en el ACF, esta interpretación debe hacerse con precaución, puesto a que la serie es de naturaleza periodica en los datos (sinusoidal) puede hacer que se lleguen a conclusiones erroneas en la interpretación del ACF.

Hecho todo esto, se procede a identificar el mejor modelo ARIMA con la función `auto.arima` teniendo en cuenta que no se tomará el ultimo año (1982) para posteriormente probar el rendimiento del modelo

```
library(forecast)

# Identificar un modelo ARIMA estacional usando auto.arima
modelo_arima <- auto.arima(stats::window(serie_transformada, end = 60), seasonal = TRUE)

# Resumen del modelo ARIMA
summary(modelo_arima)
```

```
## Series: stats::window(serie_transformada, end = 60)
## ARIMA(3,1,0) with drift
##
## Coefficients:
##           ar1      ar2      ar3   drift
##       -0.9878  -0.9736  -0.9570  0.0566
## s.e.   0.0309   0.0340   0.0249  0.0233
##
```

```
## sigma^2 = 0.5004:  log likelihood = -65.19
## AIC=140.39   AICc=141.52   BIC=150.78
##
## Training set error measures:
##                       ME      RMSE       MAE  MPE MAPE       MASE       ACF1
## Training set 0.001891751 0.6772563 0.2287155 -Inf  Inf 0.09869984 -0.1027322
```

Teoricamente, el error medio absoluto (MAE) de pronostico es de aproximadamente 0.23. Verificando esto graficamente:

```r
# Pronóstico (excluyendo el último año de datos para la evaluación)
# Suponiendo que tienes datos trimestrales y quieres pronosticar 4 trimestres (1 año)
pronostico <- forecast(modelo_arima, h = 4)

# Graficar los pronósticos
plot(pronostico)
```

Muchachos, acá en este trabajo, en ningún momento se solicitaba el calculo de pronósticos. -4pts

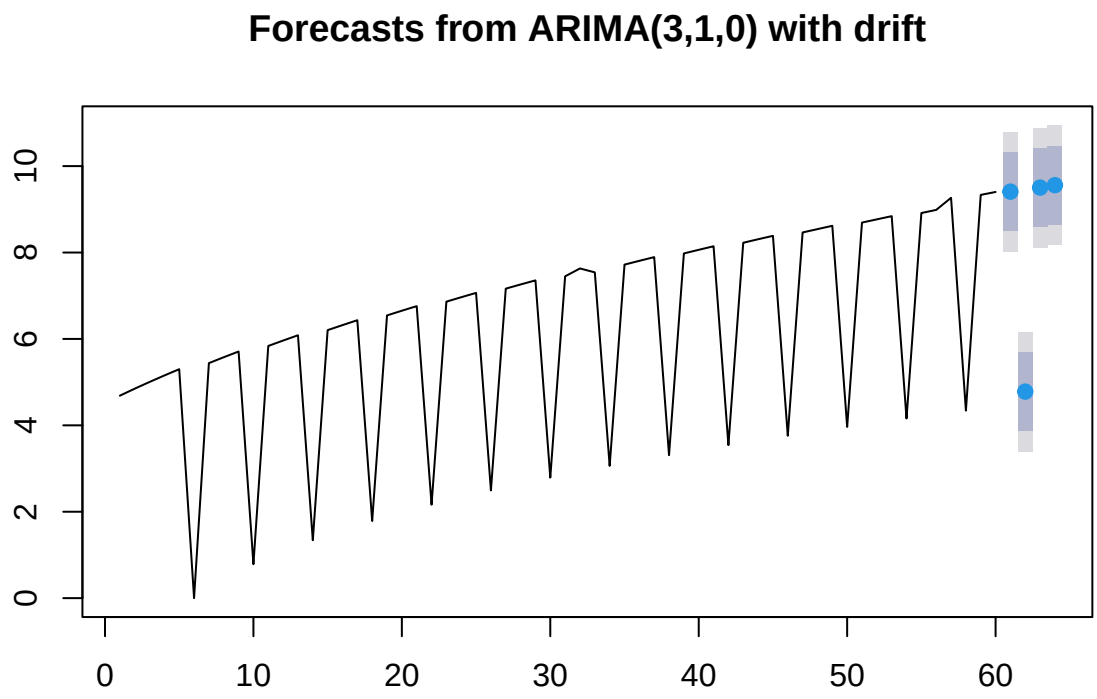


```r
plot(serie_transformada, type="l", col="blue", main="Serie Transformada (Box-Cox)",
     xlab="Tiempo", ylab="Valor Transformado")
```

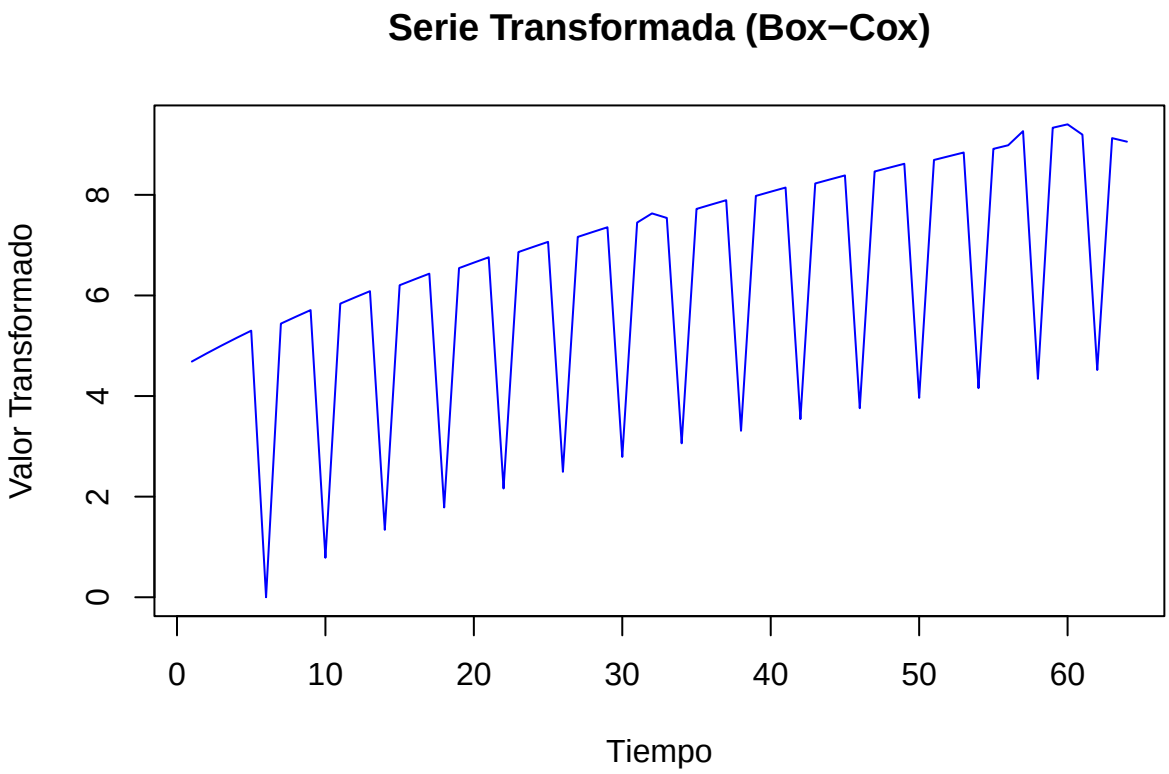

De las gráficas se puede evidenciar que los pronosticos son muy parecidos a lo valores reales de la serie transformada